

Estudo Comparativo de Estimadores de Estado num Pêndulo Invertido sob Malha de Controle

1 Introdução

Este projeto implementa e compara, **dentro de uma malha de controle fechada**, diferentes técnicas de **estimação de estados** aplicadas a um **pêndulo invertido sobre carro** (*cart-pole*) — um sistema dinâmico não-linear e naturalmente instável.

A motivação parte de uma lacuna do curso: em CMC-12 abordou-se apenas a **filtragem passa-baixas clássica**, sem estimação por espaço de estados. O trabalho avança sobre esse ponto confrontando quatro níveis de estimadores, do visto em aula ao estado da arte:

$$\underbrace{\text{Diferenciação + passa-baixas}}_{\text{baseline do curso}} \rightarrow \underbrace{\text{KF linear}}_{\text{linearizado}} \rightarrow \underbrace{\text{EKF}}_{\text{Jacobiano online}} \rightarrow \underbrace{\text{UKF}}_{\text{sigma points}} .$$

O pêndulo invertido é escolhido justamente porque o controle opera em **duas fases** que exercitam os filtros em regimes distintos: o *swing-up* (baseado em energia) leva a haste por **ângulos grandes**, num regime fortemente não-linear onde o KF linear degrada e EKF/UKF se destacam; já a *estabilização* (LQR na vertical) opera num regime quase-linear, onde todos os filtros convergem de forma semelhante. Assim, um único experimento evidencia **onde cada filtro compensa**.

Quanto ao escopo, o estado é $X = [x \ \dot{x} \ \theta \ \dot{\theta}]^T$ (posição e velocidade do carro; ângulo e velocidade angular da haste). Apenas as **posições** x e θ são medidas, com ruído (encoders); as velocidades $\dot{x}$ e $\dot{\theta}$ são estimadas. O desempenho é avaliado por RMSE por estado, tempo de convergência, robustez (ruído alto, baixa taxa de amostragem, erro de sintonia de Q/R , má inicialização), consistência estatística (NEES/NIS) e custo computacional, comparando ainda a malha fechada com estado estimado *vs.* estado ideal (princípio da separação na prática).

1.1 Parâmetros adotados


Todas as constantes físicas e de simulação são centralizadas em `params.m` (fonte única de verdade) e resumidas na Tabela 1. A haste é modelada como barra uniforme, de modo que o momento de inércia em torno do centro de massa é $I = \frac{1}{3}mL^2$.

Grandeza	Símbolo	Valor
Massa do carro	M	1,0 kg
Massa da haste	m	0,3 kg
Distância pivô-CM	L	0,5 m
Inércia da haste (CM)	$I = \frac{1}{3}mL^2$	0,025 kg·m ²
Atrito viscoso do carro	b	0,1 N·s/m
Gravidade	g	9,81 m/s ²
Passo de amostragem	Δt	0,01 s (100 Hz)
Horizonte de simulação	T_f	10 s (padrão)
Ruído do encoder (x)	σ_x	0,005 m
Ruído do encoder (θ)	σ_θ	0,005 rad

Tabela 1: Parâmetros físicos, de simulação e de medição adotados no projeto.

2 Planta de controle

No referencial não inercial do carrinho:



$$u + F_x - b\dot{x} = M\ddot{x} \quad (1)$$

$$mgL \sin \theta + m\ddot{x} L \cos \theta = (I + mL^2) \ddot{\theta} \quad (2)$$

$$F_x + m\ddot{x} = m \left(L\ddot{\theta} \cos \theta - L\dot{\theta}^2 \sin \theta \right) \quad (3)$$

Substituindo F_x da equação (3) na equação (1):

$$u + m \left(-\ddot{x} + L\ddot{\theta} \cos \theta - L\dot{\theta}^2 \sin \theta \right) - b\dot{x} = M\ddot{x}$$

Reorganizando, chega-se ao sistema:

$$\begin{cases} u = (M + m)\ddot{x} + b\dot{x} - mL\ddot{\theta}\cos\theta + mL\dot{\theta}^2\sin\theta \\ mL\ddot{x}\cos\theta = (I + mL^2)\ddot{\theta} - mgL\sin\theta \end{cases}$$

Escolhemos como vetor de estado

$$X = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} x \\ \dot{x} \\ \theta \\ \dot{\theta} \end{bmatrix}, \quad \text{de modo que} \quad \dot{X} = \begin{bmatrix} \dot{x} \\ \ddot{x} \\ \dot{\theta} \\ \ddot{\theta} \end{bmatrix} = \begin{bmatrix} x_2 \\ x_4 \\ x_3 \\ x_1 \end{bmatrix}.$$

Como $\dot{x}_1 = x_2$ e $\dot{x}_3 = x_4$ são imediatos, resta obter expressões explícitas para $\ddot{x}$ e $\ddot{\theta}$. Reescrevendo o sistema com os termos de aceleração à esquerda:

$$\begin{aligned} (M + m)\ddot{x} - mL\cos\theta\ddot{\theta} &= u - b\dot{x} - mL\dot{\theta}^2\sin\theta \\ -mL\cos\theta\ddot{x} + (I + mL^2)\ddot{\theta} &= mgL\sin\theta \end{aligned}$$

Podemos usar o formato matricial

$$\underbrace{\begin{bmatrix} M + m & -mL\cos\theta \\ -mL\cos\theta & I + mL^2 \end{bmatrix}}_A \begin{bmatrix} \ddot{x} \\ \ddot{\theta} \end{bmatrix} = \begin{bmatrix} u - b\dot{x} - mL\dot{\theta}^2\sin\theta \\ mgL\sin\theta \end{bmatrix}.$$

Para simplificar, definimos

$$\begin{aligned} a &= M + m, & h &= mL\cos\theta, & J &= I + mL^2, \\ r_1 &= u - b\dot{x} - mL\dot{\theta}^2\sin\theta, & r_2 &= mgL\sin\theta, \end{aligned}$$

de forma que $A = \begin{bmatrix} a & -h \\ -h & J \end{bmatrix}$.

O determinante é

$$\Delta = \det A = aJ - h^2 = (M + m)(I + mL^2) - m^2L^2\cos^2\theta,$$

e a inversa de uma matriz 2×2 simétrica é

$$A^{-1} = \frac{1}{\Delta} \begin{bmatrix} J & h \\ h & a \end{bmatrix}.$$

Logo,

$$\begin{bmatrix} \ddot{x} \\ \ddot{\theta} \end{bmatrix} = \frac{1}{\Delta} \begin{bmatrix} J & h \\ h & a \end{bmatrix} \begin{bmatrix} r_1 \\ r_2 \end{bmatrix} \implies \begin{aligned} \ddot{x} &= \frac{Jr_1 + hr_2}{\Delta}, \\ \ddot{\theta} &= \frac{hr_1 + ar_2}{\Delta}. \end{aligned}$$

Substituindo a , h , J , r_1 e r_2 :

$$\ddot{x} = \frac{(I + mL^2)(u - b\dot{x} - mL\dot{\theta}^2 \sin \theta) + mL \cos \theta (mgL \sin \theta)}{(M + m)(I + mL^2) - m^2L^2 \cos^2 \theta},$$

$$\ddot{\theta} = \frac{mL \cos \theta (u - b\dot{x} - mL\dot{\theta}^2 \sin \theta) + (M + m)(mgL \sin \theta)}{(M + m)(I + mL^2) - m^2L^2 \cos^2 \theta}.$$

Para a haste uniforme, $I = \frac{mL^2}{3}$, de modo que $I + mL^2 = \frac{4}{3}mL^2$.

Reunindo tudo, com $X = [x \ \dot{x} \ \theta \ \dot{\theta}]^T$:

$$\dot{X} = \begin{bmatrix} \dot{x}_1 \\ \dot{x}_2 \\ \dot{x}_3 \\ \dot{x}_4 \end{bmatrix} = \begin{bmatrix} x_2 \\ \frac{(I + mL^2)(u - b x_2 - mL x_4^2 \sin x_3) + m^2 g L^2 \sin x_3 \cos x_3}{(M + m)(I + mL^2) - m^2 L^2 \cos^2 x_3} \\ x_4 \\ \frac{mL \cos x_3 (u - b x_2 - mL x_4^2 \sin x_3) + (M + m) mgL \sin x_3}{(M + m)(I + mL^2) - m^2 L^2 \cos^2 x_3} \end{bmatrix}.$$

3 Linearização em torno da vertical

O objetivo do controlador de estabilização é manter a haste na vertical ($\theta = 0$). Linearizamos, portanto, a dinâmica em torno do equilíbrio

$$X_{eq} = [0 \ 0 \ 0 \ 0]^T, \quad u_{eq} = 0,$$

usando as aproximações de pequenos ângulos e desprezando os termos de segunda ordem (o produto $\dot{\theta}^2 \sin \theta$ é de ordem superior e se anula):

$$\cos \theta \approx 1, \quad \sin \theta \approx \theta, \quad \dot{\theta}^2 \sin \theta \approx 0.$$

Nessas condições o determinante deixa de depender de θ (sua dependência é em $\cos^2 \theta$, cuja derivada em $\theta = 0$ é nula):

$$\Delta_0 = (M + m)(I + mL^2) - m^2L^2 = mL^2 \left[\frac{4}{3}(M + m) - m \right].$$

As expressões de $\ddot{x}$ e $\ddot{\theta}$ tornam-se lineares:

$$\ddot{x} \approx -\frac{(I + mL^2)b}{\Delta_0} \dot{x} + \frac{m^2L^2g}{\Delta_0} \theta + \frac{I + mL^2}{\Delta_0} u,$$

$$\ddot{\theta} \approx -\frac{mLb}{\Delta_0} \dot{x} + \frac{(M + m)mgL}{\Delta_0} \theta + \frac{mL}{\Delta_0} u.$$

Escrevendo $\dot{X} = AX + Bu$, obtemos a *matriz de estados* A e a *matriz de entrada* B :

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & -\frac{(I + mL^2)b}{\Delta_0} & \frac{m^2L^2g}{\Delta_0} & 0 \\ 0 & 0 & 0 & 1 \\ 0 & -\frac{mLb}{\Delta_0} & \frac{(M + m)mgL}{\Delta_0} & 0 \end{bmatrix}, \quad B = \begin{bmatrix} 0 \\ \frac{I + mL^2}{\Delta_0} \\ 0 \\ \frac{mL}{\Delta_0} \end{bmatrix}.$$

O termo $A_{4,3} = (M + m)mgL/\Delta_0 > 0$ confirma que a vertical é um equilíbrio **instável**: um desvio $\theta > 0$ gera $\ddot{\theta} > 0$, afastando ainda mais a haste. É esse comportamento que a realimentação LQR corrige.

Instabilidade pelo critério de Routh-Hurwitz. Isolando o modo da haste (equação de $\ddot{\theta}$ linearizada), desprezando o acoplamento com o carro e o atrito e tomando $u = 0$, resulta $\ddot{\theta} - A_{4,3}\theta = 0$, cujo polinômio característico é

$$P(s) = s^2 + 0 \cdot s - A_{4,3}, \quad A_{4,3} = \frac{(M + m)mgL}{\Delta_0} = 17,795 > 0.$$

A *condição necessária* de estabilidade de Routh-Hurwitz exige que todos os coeficientes estejam presentes e tenham o mesmo sinal. Aqui ela já é violada em dois pontos: o coeficiente de s^1 está ausente ($a_1 = 0$) e o termo independente $a_2 = -A_{4,3}$ tem sinal oposto ao de $a_0 = 1$. Logo, $P(s)$ não pode ter todas as raízes no semiplano esquerdo.

Montando o arranjo de Routh (com a substituição $a_1 \rightarrow \varepsilon \rightarrow 0^+$ para o zero na primeira coluna):

$$\begin{array}{c|cc} s^2 & 1 & -A_{4,3} \\ s^1 & \varepsilon & 0 \\ s^0 & -A_{4,3} & \end{array}$$

A primeira coluna é $1, \varepsilon, -A_{4,3}$, isto é, $(+), (+), (-)$: ocorre **uma** troca de sinal, indicando **uma raiz no semiplano direito**. De fato, as raízes exatas são $s = \pm\sqrt{A_{4,3}} = \pm 4,22$, e a raiz $+4,22$ (modo $e^{+4,22t}$) é a que faz a haste cair. O termo $-A_{4,3}$ comporta-se como uma “constante de mola negativa”: é esse polo instável que a realimentação LQR reposiciona no semiplano esquerdo.

Valores numéricos. Com $M = 1,0$ kg, $m = 0,3$ kg, $L = 0,5$ m, $g = 9,81$ m/s², $b = 0,1$ N·s/m e $I = mL^2/3 = 0,025$ kg·m², tem-se $I + mL^2 = 0,1$ e $\Delta_0 = 0,1075$, resultando em

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & -0,0930 & 2,0533 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & -0,1395 & 17,795 & 0 \end{bmatrix}, \quad B = \begin{bmatrix} 0 \\ 0,9302 \\ 0 \\ 1,3953 \end{bmatrix}.$$

4 Projeto do controlador LQR

A escolha do LQR se justifica pela própria natureza do problema. A planta é **instável** em malha aberta (Seção anterior, critério de Routh-Hurwitz): sem realimentação a haste inevitavelmente cai, de modo que um controlador ativo é obrigatório. Além disso, o cart-pole é um sistema de **quatro estados fortemente acoplados com uma única entrada** (u , a força no carro); técnicas clássicas de malha única (como um PID por variável) tornam-se difíceis de sintonizar nesse cenário multivariável, pois a mesma força precisa regular simultaneamente posição do carro e ângulo da haste. A realimentação de estados $u = -KX$ ataca todos os estados de uma vez, e o LQR fornece um critério **sistemático e ótimo** para escolher os quatro ganhos de K : em vez de posicionar polos por tentativa, minimiza-se um índice de desempenho que equilibra explicitamente o *erro de regulação* (via Q) contra o *esforço de controle* (via R). Como consequência, desde que o par (A, B) seja controlável, o LQR garante malha fechada estável e apresenta boas margens de robustez. Por fim, o LQR encaixa-se naturalmente no tema deste trabalho: pelo princípio da separação, o ganho projetado sobre o estado verdadeiro pode operar sobre o estado *estimado* ($u = -K\hat{X}$), permitindo comparar o desempenho da malha alimentada por cada estimador (KF, EKF, UKF).

4.1 Controlabilidade

Antes de projetar, verifica-se que o par (A, B) é controlável, isto é, que a matriz de controlabilidade tem posto completo:

$$\mathcal{C} = [B \ AB \ A^2B \ A^3B], \quad \text{posto}(\mathcal{C}) = 4.$$

Para o cart-pole isso se verifica: uma única força aplicada ao carro é capaz de governar os quatro estados.

4.2 Formulação do problema

O regulador linear quadrático escolhe a lei de realimentação de estados $u = -KX$ que minimiza o funcional de custo

$$J = \int_0^\infty (X^\top Q X + u^\top R u) dt, \quad Q = Q^\top \succeq 0, \quad R = R^\top \succ 0,$$

em que Q pondera o erro de estado e R pondera o esforço de controle. O ganho ótimo é

$$K = R^{-1}B^\top P,$$

onde $P = P^\top \succeq 0$ é a solução da equação algébrica de Riccati (ARE)

$$A^\top P + PA - PBR^{-1}B^\top P + Q = 0.$$

Para um sistema de quarta ordem a ARE não é resolvida à mão; obtém-se P (e daí K) numericamente (Seção 4.4).

4.3 Escolha de Q e R (regra de Bryson)

Como ponto de partida sistemático, aplica-se a *regra de Bryson*: cada peso é o inverso do quadrado do desvio máximo aceitável para aquela variável,

$$Q_{ii} = \frac{1}{x_{i,\max}^2}, \quad R = \frac{1}{u_{\max}^2}.$$

Adotando os limites físicos $x_{\max} = 0,5$ m, $\dot{x}_{\max} = 2$ m/s, $\theta_{\max} = 10^\circ \approx 0,175$ rad, $\dot{\theta}_{\max} = 2$ rad/s e $u_{\max} = 20$ N:

$$Q = \text{diag}(4; 0,25; 32,8; 0,25), \quad R = 0,0025.$$

Esses valores são apenas o ponto de partida; a sintonia final é iterativa (aumentar Q_{33} deixa o ângulo mais firme; aumentar R torna a resposta mais suave e econômica em força).

4.4 Cálculo do ganho no MATLAB

Com A , B , Q e R definidos, o ganho é obtido pela função `lqr` (requer a *Control System Toolbox*). O trecho abaixo reaproveita o Jacobiano analítico já implementado (`jacobian_f.m`) para montar A :

```
p = params(); % parametros fisicos
A = jacobian_f([0;0;0;0], 0, p); % matriz de estados (Jacobiano em theta=0)

d = p.m*p.L^2/3 + p.m*p.L^2; % I + mL^2
k = p.m*p.L; % mL
a = p.M + p.m; % M + m
Delta = a*d - k^2; % determinante em theta = 0
B = [0; d/Delta; 0; k/Delta]; % matriz de entrada

assert(rank(ctrb(A,B)) == 4, 'par (A,B) nao controlavel');

Q = diag([1/0.5^2, 1/2^2, 1/deg2rad(10)^2, 1/2^2]);
R = 1/20^2;

K = lqr(A, B, Q, R) % ganho otimo -> guardar em p.K_lqr
eig(A - B*K) % polos de malha fechada (Re < 0 => estavel)
```

O ganho resultante (valores de referência) é

$$K = [-40,00 \quad -42,14 \quad 217,20 \quad 48,46],$$

com polos de malha fechada

$$s_{1,2} = -12,8126 \pm 2,5904j,$$

$$s_{3,4} = -1,4435 \pm 1,0585j,$$

todos com parte real negativa, o que confirma a estabilização da vertical.

5 Controle de *swing-up* energético

O LQR só estabiliza a haste dentro de uma pequena vizinhança da vertical (sua região de atração). Quando o pêndulo parte pendurado, é preciso primeiro **levá-lo até essa vizinhança**. Como a linearização não vale para ângulos grandes, usa-se uma estratégia não-linear baseada em **energia** (*energy shaping*), seguindo a formulação de Tedrake [2] e o método clássico de Åström e Furuta [3]: em vez de seguir uma trajetória, injeta-se energia no pêndulo balançando o carro no ritmo certo, até que ele tenha energia suficiente para alcançar a vertical.

5.1 Energia do pêndulo

Adotamos a notação de [2]. A energia da haste é a soma das parcelas cinética T e potencial U ,

$$E(\theta, \dot{\theta}) = T(\dot{\theta}) + U(\theta), \quad T = \frac{1}{2}I\dot{\theta}^2, \quad U = -mgl \cos \theta,$$

onde I é o momento de inércia efetivo em torno do pivô e l a distância do pivô ao centro de massa. Para a haste uniforme deste trabalho, $I = \frac{1}{3}mL^2 + mL^2 = \frac{4}{3}mL^2$ e $l = L$.

Observação de convenção. A referência [2] mede θ a partir da posição **pendurada** ($\theta = 0$ embaixo), de modo que $U = -mgl \cos \theta$ é mínimo embaixo. Na modelagem deste relatório $\theta = 0$ é a **vertical superior**; as duas convenções diferem apenas por uma defasagem de π e um sinal no termo potencial, sem alterar a lei de controle.

A energia da órbita que alcança o equilíbrio superior instável (energia desejada) é, como em [2],

$$E^d = mgl.$$

O objetivo do *swing-up* é levar E até E^d . Define-se o erro de energia

$$\tilde{E} = E - E^d.$$

5.2 Lei de *energy shaping*

Para o pêndulo simples atuado por torque na junta, [2] mostra que a lei

$$u = -k\dot{\theta}\tilde{E}, \quad k > 0,$$

produz a dinâmica de erro $\dot{\tilde{E}} = -k\dot{\theta}^2\tilde{E}$, que faz $\tilde{E} \rightarrow 0$. Isso decorre da função de Lyapunov $V = \frac{1}{2}\tilde{E}^2 \geq 0$, cuja derivada é

$$\dot{V} = \tilde{E}\dot{\tilde{E}} = -k\dot{\theta}^2\tilde{E}^2 \leq 0.$$

No cart-pole a entrada não é um torque na junta, mas a **força** u no carro, que atua sobre a haste através da aceleração do pivô $\ddot{x}$. Da equação de movimento da haste, $I\ddot{\theta} = mgl \sin \theta + ml \cos \theta \ddot{x}$, obtém-se

$$\dot{\tilde{E}} = ml \cos \theta \dot{\theta} \ddot{x}$$

— os termos gravitacionais se cancelam e a energia só varia por meio de $\ddot{x}$. Repetindo o argumento de Lyapunov com $\dot{V} = \tilde{E} \dot{E} = \tilde{E} ml \cos \theta \dot{\theta} \ddot{x}$ e escolhendo $\ddot{x} \propto -\dot{\theta} \tilde{E} \cos \theta$, resulta $\dot{V} = -k ml \tilde{E}^2 \dot{\theta}^2 \cos^2 \theta \leq 0$. A lei de *energy shaping* adaptada ao cart-pole é, portanto, a de [2] com o fator geométrico $\cos \theta$:

$$u = -k \dot{\theta} \tilde{E} \cos \theta, \quad u \leftarrow \text{sat}_{\pm u_{max}}(u).$$

Quando falta energia ($\tilde{E} < 0$) a lei injeta energia ($\dot{E} > 0$); ao atingir E^d o termo se anula. Nos pontos de retorno ($\dot{\theta} = 0$) e na horizontal ($\cos \theta = 0$) tem-se $u = 0$.

5.3 Regulação da posição do carro

A lei de *energy shaping* pura tem uma limitação conhecida: ela governa a **energia da haste**, mas não faz nenhuma referência à **posição do carro**. Como o bombeamento empurra o carro sempre no sentido que adiciona energia, o carro deriva sem limite (nas simulações, dezenas de metros), e o LQR recebe a haste no topo com o carro deslocado — condição fora de sua região de atração, de modo que a captura falha.

A solução clássica, seguindo Chung e Spong [5] e Tedrake [4], é somar à lei de *energy shaping* um controlador **PD sobre o carro**, que o mantém próximo da origem sem impedir o balanço:

$$u = -k_{swing} \dot{\theta} \tilde{E} \cos \theta - \underbrace{k_p x - k_d \dot{x}}_{\text{PD no carro}}, \quad u \leftarrow \text{sat}_{\pm u_{max}}(u).$$

O termo $-k_p x$ age como uma mola que puxa o carro de volta a $x = 0$ e $-k_d \dot{x}$ como amortecimento. Optou-se por um PD (e não PI/PID): o *swing-up* é um transitório curto sob uma “perturbação” oscilatória (o próprio bombeamento troca de sinal a cada balanço), sem erro de regime permanente a corrigir — um termo integral apenas acumularia esse sinal (*windup*) e brigaria com o bombeamento. Os ganhos adotados, obtidos por busca em simulação, são

$$k_{swing} = 12, \quad k_p = 5, \quad k_d = 2,$$

com os quais a haste sobe e é capturada em torno de 1,2 s (estado ideal, sem ruído). Trata-se de um ponto de partida: os ganhos podem ser reotimizados (por exemplo, minimizando o tempo de subida sob restrição da excursão do carro).

5.4 Comutação para o LQR

O *swing-up* entrega a haste dentro da região de atração do LQR. Adota-se uma condição de comutação por ângulo e velocidade pequenos,

$$|\theta| < 15^\circ \quad \text{e} \quad |\dot{\theta}| < 2 \text{ rad/s} \implies \text{muda para } u = -K\hat{X},$$

combinando a fase não-linear (energia) com a fase linear (LQR) num único controlador de duas fases, exatamente o cenário que exercita os estimadores em regimes distintos.

6 Modelo de sensores e cenários de teste

O modelo de sensores é a interface entre a “verdade” do simulador e o que os estimadores efetivamente observam: recebe o estado verdadeiro e devolve uma medição imperfeita. Como os filtros nunca acessam X diretamente, é este modelo que torna o problema de estimação realista.

6.1 Grandezas medidas

Apenas as **posições** são medidas, reproduzindo um par de encoders na posição do carro e no ângulo da haste; as velocidades $\dot{x}$ e $\dot{\theta}$ não são medidas e devem ser estimadas. A medição é, portanto,

$$z_k = \begin{bmatrix} x \\ \theta \end{bmatrix}_{t_k} + v_k, \quad v_k \sim \mathcal{N}(0, R), \quad R = \text{diag}(\sigma_x^2, \sigma_\theta^2),$$

com ruído branco gaussiano e independente por canal. Os desvios nominais são $\sigma_x = \sigma_\theta = 0,005$ (Tabela 1). Essa escolha — medir só posições — é o que dá sentido à comparação de estimadores: obter $\dot{x}$ e $\dot{\theta}$ é exatamente a tarefa que separa a simples diferenciação com passagens baixas dos filtros baseados em modelo (KF/EKF/UKF).

6.2 Degradações e escolhas de projeto

Além do ruído nominal, o sensor reproduz três degradações, acionadas por parâmetros dos cenários (Seção de resultados). As escolhas de modelagem foram:

- **Ruído elevado (S3).** Multiplica-se σ_x e σ_θ por um fator ($10\times$). Testa a filtragem quando a relação sinal-ruído cai, favorecendo estimadores que ponderam corretamente medição *vs.* modelo.
- **Dropout de medida (S4).** A cada passo, com probabilidade p_{drop} , a leitura é **totalmente perdida**. Optou-se por sinalizar a perda com uma medição *vazia* ($z_k = \emptyset$), em vez de um valor qualquer, para que o estimador execute um passo de **predição pura** (sem atualização): a média é propagada pelo modelo e a covariância P cresce, refletindo corretamente o aumento de incerteza. Zerar ou congelar a medição daria ao filtro uma confiança falsa, corrompendo a análise de consistência (NEES/NIS).
- **Outliers.** Cada canal, com probabilidade p_{out} , recebe um pico espúrio de amplitude proporcional a σ (por padrão 30σ) e sinal aleatório. Modela leituras absurdas e ocasionais, que um estimador robusto deve rejeitar. É desligado por padrão ($p_{out} = 0$) e destina-se a um teste opcional de robustez.

Todas as degradações têm probabilidade nula por padrão, de forma que os cenários sem *override* usam apenas o ruído gaussiano nominal e permanecem comparáveis entre si.

7 Estimadores de Estado Clássicos: da Diferenciação ao Filtro de Kalman Linear

Esta seção descreve os três estimadores "clássicos" do projeto — isto é, os que não dependem de linearização *online* nem de amostragem estocástica do espaço de estados, ao contrário do EKF e do UKF, tratados na seção seguinte¹. Os três compartilham a mesma interface de *drop-in* definida no contrato do projeto,

$$[\hat{X}_k, P_k] = \text{estimator_update}(\hat{X}_{k-1}, P_{k-1}, z_k, u_k, p),$$

e atuam sobre a mesma medição de posições $z_k = [x \ \theta]_{t_k}^T$ definida na Seção 6, mas diferem radicalmente na quantidade de **modelo** que incorporam: da ausência total de modelo dinâmico (baseline), passando por um modelo aproximado e implícito (complementar), até o modelo linear completo do pêndulo, explicitamente propagado com sua incerteza estatística (Kalman linear). Essa progressão prepara o terreno para o EKF e o UKF (Seção seguinte), que estendem o mesmo princípio de propagação de covariância ao modelo *não-linear* do cart-pole.

7.1 Baseline do curso: diferenciação numérica com filtro passa-baixas

O primeiro estimador (`est_lowpass.m`) reproduz exatamente a técnica vista em CMC-12: um filtro passa-baixas digital de primeira ordem (média móvel exponencial) aplicado à medição, seguido de diferenciação numérica para obter as velocidades [14]. Para cada canal medido,

$$\tilde{x}_k = \alpha \tilde{x}_{k-1} + (1 - \alpha) z_{x,k}, \quad \tilde{\theta}_k = \alpha \tilde{\theta}_{k-1} + (1 - \alpha) z_{\theta,k}, \quad \alpha \in (0, 1),$$

e as velocidades são obtidas por diferença atrasada (*backward difference*) do sinal já filtrado:

$$\hat{x}_k = \frac{\tilde{x}_k - \tilde{x}_{k-1}}{\Delta t}, \quad \hat{\theta}_k = \frac{\tilde{\theta}_k - \tilde{\theta}_{k-1}}{\Delta t}.$$

Esse filtro recursivo de primeiro grau é o análogo discreto de um passa-baixas *RC* contínuo com constante de tempo $\tau = -\Delta t / \ln \alpha$, ou, equivalentemente, frequência de corte $f_c = \frac{1}{2\pi\tau} = \frac{-\ln \alpha}{2\pi \Delta t}$ [14]. Com o valor padrão do código, $\alpha_{lp} = 0,8$, e $\Delta t = 0,01$ s (Tabela 1), obtém-se $f_c \approx 3,55$ Hz: qualquer conteúdo do sinal acima dessa frequência — inclusive parte da dinâmica real do *swing-up*, que é rápida e fortemente não-linear — é atenuado e atrasado junto com o ruído do encoder.

Esse é precisamente o ponto fraco do baseline, e a razão de ele servir de referência inferior na comparação: **não há nenhum modelo da planta** embutido no filtro. Quanto maior α , menor o ruído mas maior o atraso de fase (*lag*) — o mesmo compromisso ruído *vs.* atraso de qualquer filtro passa-baixas clássico [14] — e não existe forma de reduzir simultaneamente os dois, porque o filtro não distingue ruído de medição de dinâmica real do sistema. Note-se ainda

¹que for usado) assim que a seção de EKF/UKF do(a) colega responsável pela Seção C for integrada a este documento — ainda não existe no momento em que este texto foi escrito.

que a covariância P não tem significado probabilístico aqui: o código apenas a repassa adiante ($P = P_{\text{prev}}$) só para respeitar a interface comum, já que não há modelo de incerteza a propagar.

7.2 Filtro complementar

O segundo estimador (`est_complementary.m`) já incorpora uma noção mínima de modelo: a cada passo, prediz a posição por integração de Euler à frente supondo velocidade constante,

$$x_{\text{pred}} = \hat{x}_{k-1} + \Delta t \hat{\dot{x}}_{k-1}, \quad \theta_{\text{pred}} = \hat{\theta}_{k-1} + \Delta t \hat{\dot{\theta}}_{k-1},$$

e funde essa predição com a medição bruta usando um ganho fixo $\alpha_{\text{comp}} \in (0, 1)$,

$$x_{\text{fused}} = (1 - \alpha_{\text{comp}}) x_{\text{pred}} + \alpha_{\text{comp}} z_{x,k}, \quad \theta_{\text{fused}} = (1 - \alpha_{\text{comp}}) \theta_{\text{pred}} + \alpha_{\text{comp}} z_{\theta,k},$$

com as velocidades novamente obtidas por diferença atrasada do sinal fundido. O nome "complementar" vem da interpretação clássica no domínio da frequência introduzida por Higgins [10]: dados dois sensores (ou, aqui, um sensor e um modelo) que medem a mesma grandeza com espectros de ruído complementares, pondera-se cada fonte por um par de filtros $H(s)$ e $1 - H(s)$ que somam a unidade —

$$\hat{X}(s) = H(s) Z(s) + (1 - H(s)) X_{\text{pred}}(s),$$

de modo que a medição (tipicamente confiável em baixa frequência, mas ruidosa em alta) e o modelo/predição (suave, mas sujeito a deriva em regime permanente) se complementam sem a necessidade de estimar covariâncias explicitamente. A versão discreta a ganho fixo implementada aqui é a forma mais simples dessa ideia; note-se que, com o ganho padrão do código, $\alpha_{\text{comp}} = 0,02$, o filtro confia fortemente na predição (98%) e corrige lentamente pela medição (2%) a cada passo — um compromisso adequado quando o modelo de velocidade constante é razoável entre amostras, mas que ainda assim acumula deriva se mantido por muitos passos sem medição (o mesmo problema clássico de INS/AHRS discutido por Higgins [10] e por Grewal *et al.* [9]). É justamente esse ganho fixo, não-ótimo e invariante no tempo, que o Filtro de Kalman generaliza na próxima subseção: o KF pode ser visto como um filtro complementar cujo ganho K_k é recalculado a cada passo para ser o *ótimo* dado o par modelo/medição [8, 11].

7.3 Do modelo linearizado ao Filtro de Kalman discreto

7.3.1 Discretização por segurador de ordem zero (ZOH)

O terceiro estimador (`est_kf.m`) usa o modelo *linear* $\dot{X} = AX + Bu$ já obtido na Seção 3 em torno da vertical, complementado pelo modelo de medição (linear e exato, já que só se observam posições diretamente),

$$z = CX, \quad C = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}.$$

Como o KF discreto opera sobre o par (A_d, B_d) amostrado a Δt , e não sobre (A, B) contínuos, é preciso discretizar. A discretização exata de um sistema linear sob entrada constante por trecho (*zero-order hold*, ZOH) é

$$A_d = e^{A\Delta t}, \quad B_d = \int_0^{\Delta t} e^{A\tau} d\tau B,$$

resultado padrão de controle digital (ver, por exemplo, Franklin, Powell e Workman [12], ou Åström e Wittenmark [13]). Quando A é invertível, $B_d = A^{-1}(A_d - I)B$; **não é o caso aqui**: a dinâmica do cart-pole é invariante à translação (a posição x não aparece em nenhuma equação de movimento), de modo que a primeira coluna de A (Seção 3) é inteiramente nula e A é singular. O caminho numericamente robusto — e o que o MATLAB usa internamente em `c2d` — é formar a exponencial da matriz aumentada [12, 13]

$$\exp\left(\begin{bmatrix} A & B \\ 0 & 0 \end{bmatrix} \Delta t\right) = \begin{bmatrix} A_d & B_d \\ 0 & I \end{bmatrix},$$

que evita a inversão e vale mesmo com A singular. Como a saída $z = CX$ é uma relação puramente algébrica (sem dinâmica), a discretização não altera C , ou seja, $C_d = C$. É exatamente esse procedimento que a função auxiliar `linearise_upright()` (dentro de `est_kf.m`) deve executar via `c2d(ss(A_c, B_c, C_c, 0), dt, 'zoh')` — no momento em que este texto foi escrito, essa função ainda contém TODOs com A_c e B_c *placeholders* (zeros); o preenchimento correto é reaproveitar literalmente as matrizes A e B já derivadas e verificadas na Seção 3.

Para conferência, com $\Delta t = 0,01$ s e os valores numéricos de A e B já apresentados na Seção 3, a discretização ZOH fornece (calculado numericamente a partir da matriz aumentada acima)

$$A_d \approx \begin{bmatrix} 1 & 0,009995 & 1,03 \times 10^{-4} & 3,4 \times 10^{-7} \\ 0 & 0,999070 & 0,020529 & 1,03 \times 10^{-4} \\ 0 & -6,98 \times 10^{-6} & 1,000890 & 0,010003 \\ 0 & -0,001395 & 0,177987 & 1,000890 \end{bmatrix}, \quad B_d \approx \begin{bmatrix} 4,65 \times 10^{-5} \\ 0,009298 \\ 6,98 \times 10^{-5} \\ 0,013951 \end{bmatrix}.$$

Como esperado de uma discretização fiel a um passo pequeno frente à dinâmica ($\Delta t = 0,01$ s $\ll$ constantes de tempo de A , cujos polos ficam em $\pm 4,22$ e $-0,077$ rad/s — Seção 3), A_d é próxima da identidade e os autovalores de A_d (isto é, $e^{\lambda_i(A)\Delta t}$) ficam próximos de 1: um deles, $e^{+4,2266 \times 0,01} \approx 1,0430$, maior que 1 em módulo, confirma que o modo instável da haste (Seção 3) permanece instável também no domínio discreto, como deveria.

7.3.2 Algoritmo do Filtro de Kalman

Com (A_d, B_d, C_d) em mãos, o KF linear implementado segue exatamente a forma padrão de predição–correção de Kalman [6, 7, 8]:

Predição (propaga estado e incerteza pelo modelo, sem usar a medição):

$$\hat{X}_k^- = A_d \hat{X}_{k-1} + B_d u_{k-1}, \quad P_k^- = A_d P_{k-1} A_d^\top + Q,$$

Atualização (corrige com a nova medição z_k):

$$S_k = C_d P_k^- C_d^\top + R, \quad K_k = P_k^- C_d^\top S_k^{-1}, \quad \hat{X}_k = \hat{X}_k^- + K_k (z_k - C_d \hat{X}_k^-), \quad P_k = (I - K_k C_d) P_k^-,$$

em que Q e R são as covariâncias (supostas conhecidas, diagonais e constantes) do ruído de processo e de medição, respectivamente (Tabela 2 adiante). O ganho K_k não é arbitrário: é o único ganho que minimiza a incerteza remanescente $\text{tr}(P_k)$ a cada passo. Partindo da forma de Joseph $P_k = (I - K_k C_d) P_k^- (I - K_k C_d)^\top + K_k R K_k^\top$ (numericamente mais estável, adotada também no EKF do projeto), derivando $\text{tr}(P_k)$ em relação a K_k e igualando a zero obtém-se

$$\frac{\partial}{\partial K_k} \text{tr}(P_k) = 0 \implies K_k = P_k^- C_d^\top (C_d P_k^- C_d^\top + R)^{-1} = P_k^- C_d^\top S_k^{-1},$$

que é exatamente o ganho acima [6, 8]. Sob as hipóteses usuais — modelo linear, ruídos brancos, gaussianos, de média nula e descorrelacionados entre si e do estado inicial — esse ganho torna o KF o estimador de **variância mínima entre todos os estimadores lineares não enviesados** (propriedade BLUE, *Best Linear Unbiased Estimator*), e coincide com o estimador de máxima verossimilhança/MMSE quando os ruídos são gaussianos [6, 8, 9]. É essa otimalidade comprovada — e não apenas uma escolha heurística de ganho, como no filtro complementar (Seção 7.2) — que justifica o KF como o patamar de comparação "ótimo" *dentro do regime linear* para o restante do trabalho.

Escolha de Q e R . O código (`params.m`) adota, como ponto de partida,

Matriz	Valor
R (ruído de medição)	$\text{diag}(\sigma_x^2, \sigma_\theta^2) = \text{diag}(2,5 \times 10^{-5}, 2,5 \times 10^{-5})$
Q (ruído de processo)	$\text{diag}(10^{-4}, 10^{-3}, 10^{-4}, 10^{-3})$

Tabela 2: Covariâncias de ruído usadas pelo KF linear (compartilhadas com EKF/UKF via `p.Q/p.R`, salvo *override* `p.Q_kf/p.R_kf`).

R decorre diretamente do ruído físico dos encoders (Tabela 1) e não é, a rigor, um parâmetro de sintonia. Já Q modela a incerteza sobre o quanto o modelo *linearizado* deixa de representar a dinâmica real (erro de linearização, atrito não modelado, discretização, etc.) e é, na prática, um parâmetro de ajuste: Q pequeno demais faz o filtro confiar excessivamente no modelo linear e divergir fora da vizinhança da vertical (justamente o regime do *swing-up*); Q grande demais aproxima o KF de uma simples fusão ponderada, perdendo a vantagem de usar o modelo. Vale notar que o valor de Q aqui foi ajustado diretamente no tempo discreto, e não obtido pela discretização rigorosa de uma densidade espectral de ruído de processo contínuo (o que exigiria o método de Van Loan [15]); essa é uma simplificação comum em projetos aplicados [8], mas vale como ressalva ao interpretar Q como "física" em vez de "efetiva".

A consistência estatística desse ajuste de Q é o que o teste NEES (*Normalised Estimation Error Squared*), já implementado em `compute_metrics.m`, mede: sob as hipóteses acima, $e_k^\top P_k^{-1} e_k$ segue uma distribuição χ^2 com 4 graus de liberdade (dimensão do estado); um NEES sistematicamente acima do intervalo esperado indica P **otimista** (subestima o erro real — tipicamente Q ou R pequenos demais), e um NEES sistematicamente abaixo indica P **pessimista** (superestima o erro — Q ou R grandes demais) [16]. O mesmo raciocínio, aplicado à inovação $\nu_k = z_k - C_d \hat{X}_k^-$ em vez do erro de estado, dá o teste NIS (*Normalised Innovation Squared*, ainda pendente de implementação em `compute_metrics.m` no momento deste texto).

7.4 Síntese comparativa

A Tabela 3 resume as diferenças estruturais entre os três estimadores desta seção.

Estimador	Modelo dinâmico	Ganho	P tem significado estatístico?
Baseline (passa-baixas)	Nenhum	Fixo (α_{lp})	Não
Complementar	Implícito (veloc. constante)	Fixo (α_{comp})	Não
KF linear	A_d, B_d (linearizado)	Ótimo, variável (K_k)	Sim (sob hipóteses lineares/gaussianas)

Tabela 3: Comparação estrutural dos três estimadores clássicos implementados.

Metodologia (resultado preliminar, pré-Fase 2). No momento em que este texto foi escrito, a planta não-linear (`plant_cartpole.m`), o controlador (`controller_lqr.m`, `swingup.m`) e o *dropout/outliers* do sensor (`sensor_model.m`) — todos de responsabilidade da Pessoa A — ainda eram *placeholders*, de modo que o harness completo (`main.m/run_scenario.m`) ainda não roda de ponta a ponta. Para validar o código desta seção e gerar resultados enquanto isso, foi escrito `tests/test_classical_filters.m`, que (i) confere numericamente a linearização de `linearise_upright.m` contra o Jacobiano analítico independente `jacobian_f.m` (Pessoa C) — as duas linearizações, feitas por pessoas diferentes, batem a menos de 10^{-8} ; (ii) simula uma trajetória próxima ao cenário S1 (haste a 5° da vertical) sob realimentação de estado *apenas para fins de demonstração*, usando o ganho K já publicado na Seção 4.4 — não é o `controller_lqr.m` definitivo, que continua em aberto; e (iii) roda os três estimadores desta seção em paralelo sobre essa trajetória, com o ruído nominal e com o multiplicador $10\times$ do cenário S3. Quando a Fase 2 do fluxo do projeto (README) estiver pronta, os mesmos gráficos devem ser regenerados a partir de `run_scenario.m` com os cenários reais S1/S3, o que pode alterar os números (mas não deve alterar as conclusões qualitativas abaixo, já que a única diferença relevante é o controlador de fato usado).

Resultados. A Tabela 4 e as Figuras 1–2 resumem o que foi observado.

Estimador	RMSE θ , S1 ($^\circ$)	RMSE θ , S3 ($^\circ$)	RMSE x , S1 (m)	RMSE x , S3 (m)
Baseline (passa-baixas)	0,250	1,018	0,0031	0,0175
Complementar	1,036	2,500	0,0093	0,0388
KF linear	0,241	1,157	0,0043	0,0188

Tabela 4: RMSE de θ e de x para os três estimadores clássicos, no cenário de demonstração descrito acima, com ruído nominal (S1) e com ruído $10\times$ (S3). Valores gerados por `tests/test_classical_filters.m`.

Dois pontos merecem destaque — um deles contraria a expectativa ingênua de que "mais modelo = sempre melhor":

- **Baseline e KF praticamente empatados, ambos à frente do complementar.** No regime quase-linear e bem amostrado (100 Hz) deste cenário, o passa-baixas bem ajustado ($\alpha_{lp} = 0,8$) e o KF linear entregam RMSE de θ quase idênticos ($0,25^\circ$ vs. $0,24^\circ$ com ruído nominal). Isso **não** contradiz a otimalidade do KF (Seção 7.3.2): o KF é ótimo *dado* o par (Q, R) configurado, e neste cenário de demonstração a trajetória verdadeira é gerada por uma EDO determinística, sem ruído de processo de fato injetado — ou seja, o Q de `params.m` (Tabela 2), calibrado para representar erro de linearização e dinâmica não modelada, é relativamente "generoso" frente ao ruído de processo real (próximo de zero) deste cenário específico. Isso dá ao ganho do KF uma folga maior do que o estritamente necessário, deixando passar um pouco mais de ruído de medição do que um passa-baixas fortemente suavizante deixaria — o mesmo fenômeno de sensibilidade a Q/R misturado que o cenário S5 é desenhado para expor (Seção 7.3.2). A vantagem estrutural do KF (explorar A_d, B_d) deve ficar mais evidente quando houver ruído de processo real (p.ex. erro de linearização acumulado fora da vizinhança da vertical) ou quando Q for recalibrado — ambos fora do escopo desta seção.
- **Filtro complementar é o pior dos três, por larga margem.** A Figura 1 mostra o motivo: com o ganho padrão $\alpha_{comp} = 0,02$ (Seção 7.2), o filtro confia 98% na predição de velocidade constante a cada passo e corrige lentamente pela medição — adequado para deriva lenta, mas lento demais para acompanhar a oscilação inicial rápida de 5° deste cenário: o filtro *overshoots* a mais de 6° e só converge por volta de $t \approx 2$ s, enquanto baseline e KF acompanham a verdade quase imediatamente. Sob ruído $10\times$ (S3), seu RMSE mais que dobra ($1,04^\circ \rightarrow 2,50^\circ$), a maior degradação relativa das três — esperado, já que α_{comp} é fixo e não se adapta ao novo nível de ruído, ao contrário do ganho K_k do KF, recalculado a cada passo.

Nenhum dos três estimadores desta seção foi testado no *swing-up* (cenário S2, ângulos grandes): isso exigiria o controlador de *swing-up* (Pessoa A, ainda TODO) e, mais importante, é precisamente o regime em que a linearização por trás do KF deixa de valer — razão pela qual o EKF/UKF (Seção seguinte) são necessários, e não uma limitação deste teste específico.




Figura 1: Ângulo θ estimado pelos três estimadores clássicos no cenário de demonstração (análogo a S1, 5° de perturbação inicial, ruído nominal) *vs.* estado verdadeiro simulado. O filtro complementar (ganho fixo $\alpha_{comp} = 0,02$) *overshoota* e leva ~ 2 s para convergir; baseline e KF acompanham a verdade quase imediatamente.




Figura 2: RMSE de θ dos três estimadores clássicos no cenário de demonstração, com ruído nominal e com ruído $10\times$ (análogo a S1 *vs.* S3). O complementar tem a maior degradação relativa; baseline e KF permanecem próximos em ambos os níveis.

8 Arquitetura da malha e discussão

A Figura 3 reúne os módulos num diagrama de blocos da malha fechada. O laço opera em tempo discreto (passo Δt): a cada instante o **sensor** mede as posições ($z = [x; \theta]$ com ruído/perda), o **estimador** (KF, EKF ou UKF) reconstrói o estado completo $\hat{X}$, o **controlador** de duas fases gera a força u e a **planta** não-linear é integrada até o passo seguinte.




Figura 3: Malha de controle com estimação de estados. O controlador nunca acessa o estado verdadeiro: fecha o laço sobre a estimativa $\hat{X}$ (princípio da separação). É neste ponto que se comparam os quatro estimadores.

Dois aspectos merecem destaque na discussão. Primeiro, o **princípio da separação**: o controlador foi projetado supondo acesso ao estado, mas na prática opera sobre $\hat{X}$; a qualidade de cada estimador reflete-se diretamente no desempenho da malha, e é exatamente essa degradação que o trabalho quantifica. Segundo, o **controlador de duas fases**: longe da vertical usa a lei não-linear de *energy shaping* com o PD de carro; dentro da janela de captura comuta para o LQR linear. Assim, um único experimento leva os filtros por um regime fortemente não-linear (*swing-up*) e por um regime quase-linear (estabilização), evidenciando onde cada técnica de estimação compensa.

Referências

- [1] MathWorks. *Derive and Simulate Cart-Pole System* (Symbolic Math Toolbox). Disponível em: <https://www.mathworks.com/help/symbolic/derive-and-simulate-cart-pole-system.html>.
- [2] R. Tedrake. *Underactuated Robotics: Algorithms for Walking, Running, Swimming, Flying, and Manipulation* — Cap. *The Simple Pendulum*. Disponível em: <https://underactuated.mit.edu/pend.html>.
- [3] K. J. Åström, K. Furuta. *Swinging up a Pendulum by Energy Control*. Automatica, vol. 36, n. 2, pp. 287–295, 2000.

- [4] R. Tedrake. *Underactuated Robotics — Cap. Acrobots, Cart-Poles, and Quadrotors*. Disponível em: <https://underactuated.mit.edu/acrobot.html>.
- [5] C. C. Chung, J. Hauser. *Nonlinear control of a swinging pendulum*. Automatica, vol. 31, n. 6, pp. 851–862, 1995. Ver também M. W. Spong, *Energy Based Control of a Class of Underactuated Mechanical Systems*, IFAC World Congress, 1996.
- [6] R. E. Kalman. *A New Approach to Linear Filtering and Prediction Problems*. Journal of Basic Engineering (ASME Transactions), vol. 82, Series D, pp. 35–45, 1960.
- [7] G. Welch, G. Bishop. *An Introduction to the Kalman Filter*. Technical Report TR 95-041, University of North Carolina at Chapel Hill, 1995 (atualizado em 2006). Disponível em: https://www.cs.unc.edu/~welch/media/pdf/kalman_intro.pdf.
- [8] D. Simon. *Optimal State Estimation: Kalman, H_∞ , and Nonlinear Approaches*. Wiley, 2006.
- [9] M. S. Grewal, A. P. Andrews. *Kalman Filtering: Theory and Practice Using MATLAB*, 4.^a ed. Wiley, 2015 (1.^a ed. 1993).
- [10] W. T. Higgins. *A Comparison of Complementary and Kalman Filtering*. IEEE Transactions on Aerospace and Electronic Systems, vol. AES-11, n. 3, pp. 321–325, 1975.
- [11] R. G. Brown, P. Y. C. Hwang. *Introduction to Random Signals and Applied Kalman Filtering*, 4.^a ed. Wiley, 2012.
- [12] G. F. Franklin, J. D. Powell, M. L. Workman. *Digital Control of Dynamic Systems*, 3.^a ed. Addison-Wesley, 1997.
- [13] K. J. Åström, B. Wittenmark. *Computer-Controlled Systems: Theory and Design*, 3.^a ed. Prentice Hall, 1997.
- [14] A. V. Oppenheim, R. W. Schaffer. *Discrete-Time Signal Processing*, 3.^a ed. Prentice Hall, 2009.
- [15] C. F. Van Loan. *Computing Integrals Involving the Matrix Exponential*. IEEE Transactions on Automatic Control, vol. 23, n. 3, pp. 395–404, 1978.
- [16] Y. Bar-Shalom, X. R. Li, T. Kirubarajan. *Estimation with Applications to Tracking and Navigation: Theory, Algorithms and Software*. Wiley, 2001.