

Instituto Tecnológico de Aeronáutica - ITA
Sistemas de Controle Contínuos e Discretos - CMC-12

Alunos: Pietro Maragno Trindade Marcucci, Bernardo Affonso Cheron Vendramini, Matheus Felipe Ramos Borges

Estudo Comparativo de Estimadores de Estado num Pêndulo Invertido sob Malha de Controle

1 Introdução

Neste trabalho implementamos e comparamos, dentro de uma malha de controle fechada, quatro técnicas de estimação de estados aplicadas a um pêndulo invertido sobre carro (*cart-pole*) — um sistema não-linear e naturalmente instável.

Em CMC-12 vimos apenas a filtragem passa-baixas clássica, sem estimação por espaço de estados. Por isso confrontamos quatro níveis de estimadores, do que foi visto em aula ao estado da arte:

$$\underbrace{\text{Diferenciação + passa-baixas}}_{\text{baseline do curso}} \rightarrow \underbrace{\text{KF linear}}_{\text{linearizado}} \rightarrow \underbrace{\text{EKF}}_{\text{Jacobiano online}} \rightarrow \underbrace{\text{UKF}}_{\text{sigma points}} .$$

Escolhemos o pêndulo invertido porque o controle opera em duas fases que exercitam os filtros em regimes bem diferentes: o *swing-up* (baseado em energia) leva a haste por ângulos grandes, num regime fortemente não-linear em que o KF linear degrada e EKF/UKF se destacam; já a estabilização (LQR na vertical) opera num regime quase-linear, em que todos os filtros convergem de forma parecida. Assim, um único experimento mostra onde cada filtro compensa.

O estado é $X = [x \ \dot{x} \ \theta \ \dot{\theta}]^T$ (posição e velocidade do carro; ângulo e velocidade angular da haste). Só medimos as posições x e θ , com ruído (encoders); as velocidades $\dot{x}$ e $\dot{\theta}$ são estimadas. Avaliamos o desempenho por RMSE por estado, tempo de convergência, robustez (ruído alto, baixa taxa de amostragem, erro de sintonia de Q/R , má inicialização), consistência estatística (NEES/NIS) e custo computacional, comparando também a malha fechada com estado estimado *vs.* estado ideal (princípio da separação na prática).

1.1 Parâmetros adotados

Centralizamos todas as constantes físicas e de simulação em `params.m` e as resumimos na Tabela 1. Modelamos a haste como barra uniforme, de modo que o momento de inércia em torno do centro de massa é $I = \frac{1}{3}mL^2$.


Grandeza	Símbolo	Valor
Massa do carro	M	1,0 kg
Massa da haste	m	0,3 kg
Distância pivô-CM	L	0,5 m
Inércia da haste (CM)	$I = \frac{1}{3}mL^2$	0,025 kg·m ²
Atrito viscoso do carro	b	0,1 N·s/m
Gravidade	g	9,81 m/s ²
Passo de amostragem	Δt	0,01 s (100 Hz)
Horizonte de simulação	T_f	10 s (padrão)
Ruído do encoder (x)	σ_x	0,005 m
Ruído do encoder (θ)	σ_θ	0,005 rad

Tabela 1: Parâmetros físicos, de simulação e de medição adotados no projeto.

2 Planta de controle

Deduzimos as equações de movimento pelo procedimento de Lagrange/Newton para o cart-pole, seguindo MathWorks [1] e Tedrake [2].

No referencial não inercial do carrinho:



$$u + F_x - b\dot{x} = M\ddot{x} \quad (1)$$

$$mgL \sin \theta + m\ddot{x} L \cos \theta = (I + mL^2) \ddot{\theta} \quad (2)$$

$$F_x + m\ddot{x} = m \left(L\ddot{\theta} \cos \theta - L\dot{\theta}^2 \sin \theta \right) \quad (3)$$

Substituindo F_x da equação (3) na equação (1):

$$u + m \left(-\ddot{x} + L\ddot{\theta} \cos \theta - L\dot{\theta}^2 \sin \theta \right) - b\dot{x} = M\ddot{x}$$

Reorganizando, chegamos ao sistema:

$$\begin{cases} u = (M + m)\ddot{x} + b\dot{x} - mL\ddot{\theta} \cos \theta + mL\dot{\theta}^2 \sin \theta \\ mL\ddot{x} \cos \theta = (I + mL^2)\ddot{\theta} - mgL \sin \theta \end{cases}$$

Escolhemos como vetor de estado

$$X = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} x \\ \dot{x} \\ \theta \\ \dot{\theta} \end{bmatrix}, \quad \text{de modo que} \quad \dot{X} = \begin{bmatrix} \dot{x} \\ \ddot{x} \\ \dot{\theta} \\ \ddot{\theta} \end{bmatrix} = \begin{bmatrix} x_2 \\ x_3 \\ x_4 \\ \ddot{\theta} \end{bmatrix}.$$

Como $\dot{x}_1 = x_2$ e $\dot{x}_3 = x_4$ são imediatos, resta obter expressões explícitas para $\ddot{x}$ e $\ddot{\theta}$. Reescrevendo o sistema com os termos de aceleração à esquerda:

$$\begin{aligned} (M + m)\ddot{x} - mL \cos \theta \ddot{\theta} &= u - b\dot{x} - mL\dot{\theta}^2 \sin \theta \\ -mL \cos \theta \ddot{x} + (I + mL^2)\ddot{\theta} &= mgL \sin \theta \end{aligned}$$

Podemos usar o formato matricial

$$\underbrace{\begin{bmatrix} M + m & -mL \cos \theta \\ -mL \cos \theta & I + mL^2 \end{bmatrix}}_A \begin{bmatrix} \ddot{x} \\ \ddot{\theta} \end{bmatrix} = \begin{bmatrix} u - b\dot{x} - mL\dot{\theta}^2 \sin \theta \\ mgL \sin \theta \end{bmatrix}.$$

Para simplificar, definimos

$$\begin{aligned} a &= M + m, & h &= mL \cos \theta, & J &= I + mL^2, \\ r_1 &= u - b\dot{x} - mL\dot{\theta}^2 \sin \theta, & r_2 &= mgL \sin \theta, \end{aligned}$$

de forma que $A = \begin{bmatrix} a & -h \\ -h & J \end{bmatrix}$.

O determinante é

$$\Delta = \det A = aJ - h^2 = (M + m)(I + mL^2) - m^2 L^2 \cos^2 \theta,$$

e a inversa de uma matriz 2×2 simétrica é

$$A^{-1} = \frac{1}{\Delta} \begin{bmatrix} J & h \\ h & a \end{bmatrix}.$$

Logo,

$$\begin{bmatrix} \ddot{x} \\ \ddot{\theta} \end{bmatrix} = \frac{1}{\Delta} \begin{bmatrix} J & h \\ h & a \end{bmatrix} \begin{bmatrix} r_1 \\ r_2 \end{bmatrix} \implies \begin{aligned} \ddot{x} &= \frac{J r_1 + h r_2}{\Delta}, \\ \ddot{\theta} &= \frac{h r_1 + a r_2}{\Delta}. \end{aligned}$$

Substituindo a , h , J , r_1 e r_2 :

$$\begin{aligned} \ddot{x} &= \frac{(I + mL^2)(u - b\dot{x} - mL\dot{\theta}^2 \sin \theta) + mL \cos \theta (mgL \sin \theta)}{(M + m)(I + mL^2) - m^2 L^2 \cos^2 \theta}, \\ \ddot{\theta} &= \frac{mL \cos \theta (u - b\dot{x} - mL\dot{\theta}^2 \sin \theta) + (M + m)(mgL \sin \theta)}{(M + m)(I + mL^2) - m^2 L^2 \cos^2 \theta}. \end{aligned}$$

Para a haste uniforme, $I = \frac{mL^2}{3}$, de modo que $I + mL^2 = \frac{4}{3}mL^2$.

Reunindo tudo, com $X = [x \ \dot{x} \ \theta \ \dot{\theta}]^T$:

$$\dot{X} = \begin{bmatrix} \dot{x}_1 \\ \dot{x}_2 \\ \dot{x}_3 \\ \dot{x}_4 \end{bmatrix} = \begin{bmatrix} x_2 \\ \frac{(I + mL^2)(u - b x_2 - mL x_4^2 \sin x_3) + m^2 g L^2 \sin x_3 \cos x_3}{(M + m)(I + mL^2) - m^2 L^2 \cos^2 x_3} \\ x_4 \\ \frac{mL \cos x_3 (u - b x_2 - mL x_4^2 \sin x_3) + (M + m) mgL \sin x_3}{(M + m)(I + mL^2) - m^2 L^2 \cos^2 x_3} \end{bmatrix}.$$

3 Linearização em torno da vertical

O controlador de estabilização deve manter a haste na vertical ($\theta = 0$). Linearizamos a dinâmica em torno desse equilíbrio

$$X_{eq} = [0 \ 0 \ 0 \ 0]^T, \quad u_{eq} = 0,$$

usando as aproximações de pequenos ângulos e desprezando os termos de segunda ordem (o produto $\dot{\theta}^2 \sin \theta$ é de ordem superior e se anula):

$$\cos \theta \approx 1, \quad \sin \theta \approx \theta, \quad \dot{\theta}^2 \sin \theta \approx 0.$$

Nessas condições o determinante deixa de depender de θ (sua dependência é em $\cos^2 \theta$, cuja derivada em $\theta = 0$ é nula):

$$\Delta_0 = (M + m)(I + mL^2) - m^2 L^2 = mL^2 \left[\frac{4}{3}(M + m) - m \right].$$

As expressões de $\ddot{x}$ e $\ddot{\theta}$ tornam-se lineares:

$$\ddot{x} \approx -\frac{(I + mL^2)b}{\Delta_0} \dot{x} + \frac{m^2 L^2 g}{\Delta_0} \theta + \frac{I + mL^2}{\Delta_0} u,$$

$$\ddot{\theta} \approx -\frac{mLb}{\Delta_0} \dot{x} + \frac{(M + m)mgL}{\Delta_0} \theta + \frac{mL}{\Delta_0} u.$$

Escrevendo $\dot{X} = AX + Bu$, obtemos a *matriz de estados* A e a *matriz de entrada* B :

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & -\frac{(I + mL^2)b}{\Delta_0} & \frac{m^2 L^2 g}{\Delta_0} & 0 \\ 0 & 0 & 0 & 1 \\ 0 & -\frac{mLb}{\Delta_0} & \frac{(M + m)mgL}{\Delta_0} & 0 \end{bmatrix}, \quad B = \begin{bmatrix} 0 \\ \frac{I + mL^2}{\Delta_0} \\ 0 \\ \frac{mL}{\Delta_0} \end{bmatrix}.$$

O termo $A_{4,3} = (M + m)mgL/\Delta_0 > 0$ confirma que a vertical é um equilíbrio **instável**: um desvio $\theta > 0$ gera $\ddot{\theta} > 0$, afastando ainda mais a haste. É esse comportamento que a realimentação LQR corrige.

Instabilidade pelo critério de Routh-Hurwitz. Isolando o modo da haste (equação de $\ddot{\theta}$ linearizada), desprezando o acoplamento com o carro e o atrito e tomando $u = 0$, obtemos $\ddot{\theta} - A_{4,3} \theta = 0$, cujo polinômio característico é

$$P(s) = s^2 + 0 \cdot s - A_{4,3}, \quad A_{4,3} = \frac{(M + m)mgL}{\Delta_0} = 17,795 > 0.$$

A condição necessária de Routh-Hurwitz já falha em dois pontos: falta o coeficiente de s^1 ($a_1 = 0$) e o termo independente $a_2 = -A_{4,3}$ tem sinal oposto ao de $a_0 = 1$. Logo $P(s)$ não pode ter todas as raízes no semiplano esquerdo.

Montando o arranjo de Routh (com $a_1 \rightarrow \varepsilon \rightarrow 0^+$ para o zero na primeira coluna):

$$\begin{array}{c|cc} s^2 & 1 & -A_{4,3} \\ s^1 & \varepsilon & 0 \\ s^0 & -A_{4,3} & \end{array}$$

A primeira coluna é 1, ε , $-A_{4,3}$, ou seja (+), (+), (-): há uma troca de sinal, logo uma raiz no semiplano direito. As raízes exatas são $s = \pm\sqrt{A_{4,3}} = \pm 4,22$, e é a raiz $+4,22$ ($e^{+4,22t}$) que faz a haste cair. É esse polo instável que a realimentação LQR reposiciona no semiplano esquerdo.

Valores numéricos. Com $M = 1,0$ kg, $m = 0,3$ kg, $L = 0,5$ m, $g = 9,81$ m/s², $b = 0,1$ N·s/m e $I = mL^2/3 = 0,025$ kg·m², tem-se $I + mL^2 = 0,1$ e $\Delta_0 = 0,1075$, resultando em

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & -0,0930 & 2,0533 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & -0,1395 & 17,795 & 0 \end{bmatrix}, \quad B = \begin{bmatrix} 0 \\ 0,9302 \\ 0 \\ 1,3953 \end{bmatrix}.$$

4 Projeto do controlador LQR

Escolhemos o LQR porque a planta é instável em malha aberta (Seção anterior, Routh-Hurwitz): sem realimentação a haste cai, então um controlador ativo é obrigatório. Além disso, o cart-pole tem quatro estados fortemente acoplados e uma única entrada (u), o que torna um PID por variável difícil de sintonizar — a mesma força precisa regular carro e haste ao mesmo tempo. A realimentação de estados $u = -K X$ ataca os quatro estados de uma vez, e o LQR dá um critério sistemático para os ganhos de K : minimiza um índice de desempenho que equilibra erro de regulação (Q) e esforço de controle (R), em vez de posicionar polos por tentativa. Desde que (A, B) seja controlável, o LQR garante malha fechada estável com boas margens de robustez. Por fim, o LQR se encaixa no tema do trabalho: pelo princípio da separação, o mesmo ganho pode operar sobre o estado estimado ($u = -K \hat{X}$), permitindo comparar a malha alimentada por cada estimador (KF, EKF, UKF).

4.1 Controlabilidade

Antes de projetar, verificamos que o par (A, B) é controlável, isto é, que a matriz de controlabilidade tem posto completo:

$$\mathcal{C} = [B \ AB \ A^2B \ A^3B], \quad \text{posto}(\mathcal{C}) = 4.$$

Para o cart-pole isso se verifica: a força aplicada ao carro é capaz de governar os quatro estados.

4.2 Formulação do problema

O regulador linear quadrático escolhe a lei de realimentação de estados $u = -K X$ que minimiza o funcional de custo

$$J = \int_0^\infty (X^\top Q X + u^\top R u) dt, \quad Q = Q^\top \succeq 0, \quad R = R^\top \succ 0,$$

em que Q pondera o erro de estado e R pondera o esforço de controle. O ganho ótimo é

$$K = R^{-1} B^\top P,$$

onde $P = P^\top \succeq 0$ é a solução da equação algébrica de Riccati (ARE)

$$A^\top P + P A - P B R^{-1} B^\top P + Q = 0.$$

Para um sistema de quarta ordem não resolvemos a ARE à mão; obtemos P (e daí K) numericamente (Seção 4.4).

4.3 Escolha de Q e R (regra de Bryson)

Como ponto de partida, aplicamos a regra de Bryson: cada peso é o inverso do quadrado do desvio máximo aceitável para aquela variável,

$$Q_{ii} = \frac{1}{x_{i,\max}^2}, \quad R = \frac{1}{u_{\max}^2}.$$

Adotando os limites físicos $x_{\max} = 0,5$ m, $\dot{x}_{\max} = 2$ m/s, $\theta_{\max} = 10^\circ \approx 0,175$ rad, $\dot{\theta}_{\max} = 2$ rad/s e $u_{\max} = 20$ N:

$$Q = \text{diag}(4; 0,25; 32,8; 0,25), \quad R = 0,0025.$$

Esses valores são só o ponto de partida; a sintonia final foi iterativa (aumentar Q_{33} deixa o ângulo mais firme; aumentar R deixa a resposta mais suave e econômica em força).

4.4 Cálculo do ganho no MATLAB

Com A , B , Q e R definidos, obtivemos o ganho pela função `lqr` do MATLAB (*Control System Toolbox*), reaproveitando o Jacobiano analítico já implementado em `jacobian_f.m` para montar A e B em $\theta = 0$. Verificamos a controlabilidade de (A, B) antes de resolver a equação de Riccati; em seguida `lqr(A, B, Q, R)` retorna o ganho ótimo K , e `eig(A - B*K)` dá os polos de malha fechada.

O ganho obtido é

$$K = [-40,00 \quad -42,14 \quad 217,20 \quad 48,46],$$

com polos de malha fechada

$$s_{1,2} = -12,8126 \pm 2,5904j,$$

$$s_{3,4} = -1,4435 \pm 1,0585j,$$

todos com parte real negativa, o que confirma a estabilização da vertical.

5 Controle de *swing-up* energético

O LQR só estabiliza a haste perto da vertical (sua região de atração). Quando o pêndulo parte pendurado, é preciso levá-lo até essa vizinhança primeiro. Como a linearização não vale para ângulos grandes, usamos uma estratégia não-linear baseada em energia (*energy shaping*), seguindo Tedrake [2]: em vez de seguir uma trajetória, injetamos energia no pêndulo balançando o carro no ritmo certo, até ele ter energia suficiente para alcançar a vertical.

5.1 Energia do pêndulo

Adotamos a notação de [2]. A energia da haste é a soma das parcelas cinética T e potencial U ,

$$E(\theta, \dot{\theta}) = T(\dot{\theta}) + U(\theta), \quad T = \frac{1}{2}I \dot{\theta}^2, \quad U = -mgl \cos \theta,$$

onde I é o momento de inércia efetivo em torno do pivô e l a distância do pivô ao centro de massa. Para a haste uniforme deste trabalho, $I = \frac{1}{3}mL^2 + mL^2 = \frac{4}{3}mL^2$ e $l = L$.

Observação de convenção. A referência [2] mede θ a partir da posição pendurada ($\theta = 0$ embaixo), com $U = -mgl \cos \theta$ mínimo embaixo. Aqui $\theta = 0$ é a vertical superior; as duas convenções diferem só por uma defasagem de π e um sinal no termo potencial, sem alterar a lei de controle.

A energia da órbita que alcança o equilíbrio superior instável (energia desejada) é, como em [2],

$$E^d = mgl.$$

O objetivo do *swing-up* é levar E até E^d . Define-se o erro de energia

$$\tilde{E} = E - E^d.$$

5.2 Lei de *energy shaping*

Para o pêndulo simples atuado por torque na junta, [2] mostra que a lei

$$u = -k \dot{\theta} \tilde{E}, \quad k > 0,$$

produz a dinâmica de erro $\dot{\tilde{E}} = -k \dot{\theta}^2 \tilde{E}$, que faz $\tilde{E} \rightarrow 0$. Isso decorre da função de Lyapunov $V = \frac{1}{2}\tilde{E}^2 \geq 0$, cuja derivada é

$$\dot{V} = \tilde{E} \dot{\tilde{E}} = -k \dot{\theta}^2 \tilde{E}^2 \leq 0.$$

No cart-pole a entrada não é um torque na junta, mas a força u no carro, que atua sobre a haste pela aceleração do pivô $\ddot{x}$. Da equação de movimento da haste, $I \ddot{\theta} = mgl \sin \theta + ml \cos \theta \ddot{x}$, obtemos

$$\boxed{\dot{E} = ml \cos \theta \dot{\theta} \ddot{x}}$$

— os termos gravitacionais se cancelam e a energia só varia por $\ddot{x}$. Repetindo o argumento de Lyapunov com $\dot{V} = \tilde{E} \dot{E} = \tilde{E} ml \cos \theta \dot{\theta} \ddot{x}$ e escolhendo $\ddot{x} \propto -\dot{\theta} \tilde{E} \cos \theta$, chegamos a $\dot{V} = -k ml \tilde{E}^2 \dot{\theta}^2 \cos^2 \theta \leq 0$. A lei de *energy shaping* adaptada ao cart-pole fica, então, a de [2] com o fator geométrico $\cos \theta$:

$$\boxed{u = -k \dot{\theta} \tilde{E} \cos \theta, \quad u \leftarrow \text{sat}_{\pm u_{max}}(u).}$$

Quando falta energia ($\tilde{E} < 0$) a lei injeta energia ($\dot{E} > 0$); ao atingir E^d o termo se anula. Nos pontos de retorno ($\dot{\theta} = 0$) e na horizontal ($\cos \theta = 0$) tem-se $u = 0$.

5.3 Regulação da posição do carro

A lei de *energy shaping* pura tem uma limitação conhecida: governa a energia da haste, mas não diz nada sobre a posição do carro. Como o bombeamento empurra o carro sempre no sentido que adiciona energia, o carro deriva sem limite (nas simulações, dezenas de metros), e o LQR recebe a haste no topo com o carro deslocado — fora da região de atração, e a captura falha.

A solução clássica, seguindo Tedrake [2], é somar à lei de *energy shaping* um controlador PD sobre o carro, que o mantém próximo da origem sem impedir o balanço:

$$u = -k_{swing} \dot{\theta} \tilde{E} \cos \theta - \underbrace{k_p x - k_d \dot{x}}_{\text{PD no carro}}, \quad u \leftarrow \text{sat}_{\pm u_{max}}(u).$$

O termo $-k_p x$ age como uma mola que puxa o carro de volta a $x = 0$ e $-k_d \dot{x}$ como amortecimento. Optamos por um PD (e não PI/PID): o *swing-up* é um transitório curto sob uma “perturbação” oscilatória (o próprio bombeamento troca de sinal a cada balanço), sem erro de regime permanente a corrigir — um termo integral só acumularia esse sinal (*windup*) e brigaria com o bombeamento. Os ganhos, obtidos por busca em simulação, são

$$k_{swing} = 12, \quad k_p = 5, \quad k_d = 2,$$

com os quais a haste sobe e é capturada em torno de 1,2 s (estado ideal, sem ruído). É um ponto de partida: os ganhos podem ser reotimizados, por exemplo minimizando o tempo de subida sob restrição da excursão do carro.

5.4 Comutação para o LQR

O *swing-up* entrega a haste dentro da região de atração do LQR. Adotamos uma condição de comutação por ângulo e velocidade pequenos,

$$|\theta| < 15^\circ \quad \text{e} \quad |\dot{\theta}| < 2 \text{ rad/s} \implies \text{muda para } u = -K\hat{X},$$

combinando a fase não-linear (energia) com a fase linear (LQR) num único controlador de duas fases, exatamente o cenário que exercita os estimadores em regimes distintos.

5.5 Comportamento ideal de referência (sem ruído)

Antes de entrar no modelo de sensores, rodamos o cenário S0: medição perfeita ($\sigma_x = \sigma_\theta = 0$, sem *dropout* nem *outliers*), para ver o que o controlador entrega sozinho — o alvo que os estimadores tentam aproximar quando o ruído é reintroduzido. A Figura 1 mostra $\theta(t)$ e $x(t)$ para a mesma condição inicial de S2 (haste pendurada, $\theta_0 = 180^\circ$): o *swing-up* bombeia energia até a haste cruzar a vizinhança de $15^\circ/2 \text{ rad/s}$ em torno da vertical, o controlador comuta para o LQR, e a haste estabiliza em $\theta \rightarrow 0$ com o carro recentrado ($x \rightarrow 0$) em poucos segundos.




Figura 1: Comportamento ideal (S0, sem ruído de medição): ângulo θ e posição do carro x sob controle real (*swing-up* $\rightarrow$ LQR) a partir da haste pendurada. Com a medição exata, o estado estimado coincide com a verdade (KF/EKF/UKF, Seção 8.6) e esta é, portanto, a trajetória de malha fechada “sem perdas” — a referência contra a qual os cenários com ruído (S1–S6) são comparados.

6 Modelo de sensores e cenários de teste

O modelo de sensores é a interface entre a “verdade” do simulador e o que os estimadores observam: recebe o estado verdadeiro e devolve uma medição imperfeita. Como os filtros nunca acessam X diretamente, é esse modelo que torna o problema de estimação realista.

6.1 Grandezas medidas

Medimos só as posições, reproduzindo um par de encoders na posição do carro e no ângulo da haste; as velocidades $\dot{x}$ e $\dot{\theta}$ não são medidas e precisam ser estimadas. A medição é, portanto,

$$z_k = \begin{bmatrix} x \\ \theta \end{bmatrix}_{t_k} + v_k, \quad v_k \sim \mathcal{N}(0, R), \quad R = \text{diag}(\sigma_x^2, \sigma_\theta^2),$$

com ruído branco gaussiano e independente por canal. Os desvios nominais são $\sigma_x = \sigma_\theta = 0,005$ (Tabela 1). Medir só posições é o que dá sentido à comparação de estimadores: obter $\dot{x}$ e $\dot{\theta}$ é exatamente a tarefa que separa a diferenciação com passa-baixas dos filtros baseados em modelo (KF/EKF/UKF).

6.2 Degradações e escolhas de projeto

Além do ruído nominal, o sensor reproduz três degradações, acionadas pelos parâmetros dos cenários:

- **Ruído elevado (S3).** Multiplicamos σ_x e σ_θ por $10\times$. Testa a filtragem quando a relação sinal-ruído cai, favorecendo estimadores que ponderam corretamente medição *vs.* modelo.
- **Dropout de medida (S4).** A cada passo, com probabilidade p_{drop} , a leitura é totalmente perdida. Sinalizamos a perda com uma medição vazia ($z_k = \emptyset$), em vez de um valor qualquer, para que o estimador execute um passo de predição pura (sem atualização): a média é propagada pelo modelo e a covariância P cresce, refletindo o aumento de incerteza. Zerar ou congelar a medição daria ao filtro uma confiança falsa, corrompendo a análise de consistência (NEES/NIS).
- **Outliers.** Cada canal, com probabilidade p_{out} , recebe um pico espúrio de amplitude proporcional a σ (por padrão 30σ) e sinal aleatório. Modela leituras absurdas e ocasionais, que um estimador robusto deve rejeitar. Fica desligado por padrão ($p_{out} = 0$) e serve para um teste opcional de robustez.

Todas as degradações têm probabilidade nula por padrão, de forma que os cenários sem *override* usam só o ruído gaussiano nominal e ficam comparáveis entre si.

7 Estimadores de Estado Clássicos: da Diferenciação ao Filtro de Kalman Linear

Esta seção descreve os três estimadores "clássicos" do projeto — os que não dependem de linearização *online* nem de amostragem estocástica do espaço de estados, ao contrário do EKF e do UKF (Seção 8). Os três compartilham a mesma interface de *drop-in* do contrato do projeto,

$$[\hat{X}_k, P_k] = \text{estimator_update}(\hat{X}_{k-1}, P_{k-1}, z_k, u_k, p),$$

e atuam sobre a mesma medição de posições $z_k = [x \ \theta]_{t_k}^T$ (Seção 6), mas diferem na quantidade de modelo que carregam: da ausência total de modelo dinâmico (baseline), passando por um modelo implícito (complementar), até o modelo linear completo do pêndulo, propagado com sua incerteza estatística (Kalman linear). Essa progressão prepara o terreno para o EKF e o UKF (seção seguinte), que estendem o mesmo princípio de propagação de covariância ao modelo não-linear do cart-pole.

7.1 Baseline do curso: diferenciação numérica com filtro passa-baixas

O primeiro estimador (`est_lowpass.m`) reproduz exatamente a técnica vista em CMC-12: um filtro passa-baixas digital de primeira ordem (média móvel exponencial) aplicado à medição, seguido de diferenciação numérica para obter as velocidades [6]. Para cada canal medido,

$$\tilde{x}_k = \alpha \tilde{x}_{k-1} + (1 - \alpha) z_{x,k}, \quad \tilde{\theta}_k = \alpha \tilde{\theta}_{k-1} + (1 - \alpha) z_{\theta,k}, \quad \alpha \in (0, 1),$$

e as velocidades são obtidas por diferença atrasada (*backward difference*) do sinal já filtrado:

$$\hat{x}_k = \frac{\tilde{x}_k - \tilde{x}_{k-1}}{\Delta t}, \quad \hat{\theta}_k = \frac{\tilde{\theta}_k - \tilde{\theta}_{k-1}}{\Delta t}.$$

Esse filtro recursivo de primeiro grau é o análogo discreto de um passa-baixas RC contínuo com constante de tempo $\tau = -\Delta t / \ln \alpha$, ou frequência de corte $f_c = \frac{1}{2\pi\tau} = \frac{-\ln \alpha}{2\pi \Delta t}$ [6]. Com o valor padrão do código, $\alpha_{lp} = 0,8$, e $\Delta t = 0,01$ s (Tabela 1), $f_c \approx 3,55$ Hz: qualquer conteúdo do sinal acima dessa frequência — inclusive parte da dinâmica real do *swing-up*, rápida e fortemente não-linear — é atenuado e atrasado junto com o ruído do encoder.

Esse é o ponto fraco do baseline, e a razão de ele servir de referência inferior na comparação: não há nenhum modelo da planta embutido no filtro. Quanto maior α , menor o ruído mas maior o atraso de fase — o mesmo compromisso ruído *vs.* atraso de qualquer passa-baixas clássico [6] — e não dá para reduzir os dois ao mesmo tempo, porque o filtro não distingue ruído de medição de dinâmica real. A covariância P também não tem significado probabilístico aqui: o código só a repassa adiante ($P = P_{\text{prev}}$) para respeitar a interface comum, já que não há modelo de incerteza a propagar.

7.2 Filtro complementar

O segundo estimador (`est_complementary.m`) já incorpora uma noção mínima de modelo: a cada passo, prevê a posição por integração de Euler à frente supondo velocidade constante,

$$x_{pred} = \hat{x}_{k-1} + \Delta t \hat{\dot{x}}_{k-1}, \quad \theta_{pred} = \hat{\theta}_{k-1} + \Delta t \hat{\dot{\theta}}_{k-1},$$

e funde essa previsão com a medição bruta usando um ganho fixo $\alpha_{comp} \in (0, 1)$,

$$x_{fused} = (1 - \alpha_{comp}) x_{pred} + \alpha_{comp} z_{x,k}, \quad \theta_{fused} = (1 - \alpha_{comp}) \theta_{pred} + \alpha_{comp} z_{\theta,k},$$

com as velocidades novamente obtidas por diferença atrasada do sinal fundido. O nome "complementar" vem da interpretação clássica no domínio da frequência: dados dois sensores (ou, aqui, um sensor e um modelo) que medem a mesma grandeza com espectros de ruído complementares, pondera-se cada fonte por um par de filtros $H(s)$ e $1 - H(s)$ que somam a unidade —

$$\hat{X}(s) = H(s) Z(s) + (1 - H(s)) X_{pred}(s),$$

de modo que a medição (confiável em baixa frequência, mas ruidosa em alta) e o modelo/previsão (suave, mas sujeito a deriva em regime permanente) se complementam sem precisar estimar covariâncias explicitamente. A versão discreta a ganho fixo implementada aqui é a forma mais simples dessa ideia. Com o ganho padrão do código, $\alpha_{comp} = 0,02$, o filtro confia fortemente na previsão (98 %) e corrige lentamente pela medição (2 %) a cada passo — adequado quando o modelo de velocidade constante é razoável entre amostras, mas ainda assim acumula deriva se

ficar muitos passos sem medição, o problema clássico de fusão de sensores [4]. É justamente esse ganho fixo e invariante no tempo que o Filtro de Kalman generaliza na próxima subseção: o KF pode ser visto como um filtro complementar cujo ganho K_k é recalculado a cada passo para ser o ótimo dado o par modelo/medição [4].

7.3 Do modelo linearizado ao Filtro de Kalman discreto

7.3.1 Discretização por segurador de ordem zero (ZOH)

O terceiro estimador (`est_kf.m`) usa o modelo linear $\dot{X} = AX + Bu$ já obtido na Seção 3 em torno da vertical, complementado pelo modelo de medição (linear e exato, já que só observamos posições diretamente),

$$z = CX, \quad C = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}.$$

Como o KF discreto opera sobre o par (A_d, B_d) amostrado a Δt , e não sobre (A, B) contínuos, precisamos discretizar. A discretização exata de um sistema linear sob entrada constante por trecho (*zero-order hold*, ZOH) é

$$A_d = e^{A\Delta t}, \quad B_d = \int_0^{\Delta t} e^{A\tau} d\tau B,$$

resultado padrão de controle digital [4]. Quando A é invertível, $B_d = A^{-1}(A_d - I)B$; não é o caso aqui: a dinâmica do cart-pole é invariante à translação (a posição x não aparece em nenhuma equação de movimento), a primeira coluna de A (Seção 3) é inteiramente nula e A é singular. O caminho numericamente robusto — e o que o MATLAB usa internamente em `c2d` — é formar a exponencial da matriz aumentada [4]

$$\exp\left(\begin{bmatrix} A & B \\ 0 & 0 \end{bmatrix} \Delta t\right) = \begin{bmatrix} A_d & B_d \\ 0 & I \end{bmatrix},$$

que evita a inversão e vale mesmo com A singular. Como a saída $z = CX$ é uma relação puramente algébrica (sem dinâmica), a discretização não altera C : $C_d = C$. É esse procedimento que a função auxiliar `linearise_upright.m` executa via `c2d(ss(A_c, B_c, C_c, 0), dt, 'zoh')`, reaproveitando as matrizes A e B já derivadas e verificadas na Seção 3; o resultado $(p.A_d, p.B_d, p.C_d)$ é calculado uma única vez dentro de `params.m` e fica disponível a `est_kf.m` pelo struct de parâmetros. Conferimos a consistência entre essa linearização e o Jacobiano analítico de `jacobian_f.m` (Seção 8, derivado independentemente para o EKF) em `tests/test_classical_filters.m`: as duas discretizações batem a menos de 10^{-8} (Seção 7.4).

Com $\Delta t = 0,01$ s e os valores numéricos de A e B já apresentados na Seção 3, a discretização ZOH dá (calculado a partir da matriz aumentada acima)

$$A_d \approx \begin{bmatrix} 1 & 0,009995 & 1,03 \times 10^{-4} & 3,4 \times 10^{-7} \\ 0 & 0,999070 & 0,020529 & 1,03 \times 10^{-4} \\ 0 & -6,98 \times 10^{-6} & 1,000890 & 0,010003 \\ 0 & -0,001395 & 0,177987 & 1,000890 \end{bmatrix}, \quad B_d \approx \begin{bmatrix} 4,65 \times 10^{-5} \\ 0,009298 \\ 6,98 \times 10^{-5} \\ 0,013951 \end{bmatrix}.$$

Como esperado de uma discretização fiel a um passo pequeno frente à dinâmica ($\Delta t = 0,01$ s $\ll$ constantes de tempo de A , polos em $\pm 4,22$ e $-0,077$ rad/s — Seção 3), A_d fica próxima da identidade e os autovalores de A_d (isto é, $e^{\lambda_i(A)\Delta t}$) ficam próximos de 1: um deles, $e^{+4,2266 \times 0,01} \approx 1,0430$, maior que 1 em módulo, confirma que o modo instável da haste permanece instável também no domínio discreto, como esperado.

7.3.2 Algoritmo do Filtro de Kalman

Com (A_d, B_d, C_d) em mãos, o KF linear implementado segue a forma padrão de predição–correção de Kalman [3, 4]:

Predição (propaga estado e incerteza pelo modelo, sem usar a medição):

$$\hat{X}_k^- = A_d \hat{X}_{k-1} + B_d u_{k-1}, \quad P_k^- = A_d P_{k-1} A_d^\top + Q,$$

Atualização (corrige com a nova medição z_k):

$$S_k = C_d P_k^- C_d^\top + R, \quad K_k = P_k^- C_d^\top S_k^{-1}, \quad \hat{X}_k = \hat{X}_k^- + K_k (z_k - C_d \hat{X}_k^-), \quad P_k = (I - K_k C_d) P_k^-,$$

em que Q e R são as covariâncias (supostas conhecidas, diagonais e constantes) do ruído de processo e de medição (Tabela 2 adiante). O ganho K_k não é arbitrário: é o único ganho que minimiza a incerteza remanescente $\text{tr}(P_k)$ a cada passo. Partindo da forma de Joseph $P_k = (I - K_k C_d) P_k^- (I - K_k C_d)^\top + K_k R K_k^\top$ (numericamente mais estável, adotada também no EKF do projeto), derivamos $\text{tr}(P_k)$ em relação a K_k e igualamos a zero, obtendo

$$\frac{\partial}{\partial K_k} \text{tr}(P_k) = 0 \implies K_k = P_k^- C_d^\top (C_d P_k^- C_d^\top + R)^{-1} = P_k^- C_d^\top S_k^{-1},$$

que é exatamente o ganho acima [4]. Sob as hipóteses usuais — modelo linear, ruídos brancos, gaussianos, de média nula e descorrelacionados entre si e do estado inicial — esse ganho torna o KF o estimador de variância mínima entre todos os estimadores lineares não enviesados (propriedade BLUE), e coincide com o estimador de máxima verossimilhança/MMSE quando os ruídos são gaussianos [4]. É essa otimalidade comprovada — e não uma escolha heurística de ganho, como no filtro complementar (Seção 7.2) — que justifica o KF como o patamar de comparação "ótimo" dentro do regime linear para o restante do trabalho.

Escolha de Q e R . O código (`params.m`) adota como ponto de partida

Matriz	Valor
R (ruído de medição)	$\text{diag}(\sigma_x^2, \sigma_\theta^2) = \text{diag}(2,5 \times 10^{-5}, 2,5 \times 10^{-5})$
Q (ruído de processo)	$\text{diag}(10^{-4}, 10^{-3}, 10^{-4}, 10^{-3})$

Tabela 2: Covariâncias de ruído usadas pelo KF linear (compartilhadas com EKF/UKF via `p.Q/p.R`, salvo *override* `p.Q_kf/p.R_kf`).

R decorre direto do ruído físico dos encoders (Tabela 1) e não é, a rigor, um parâmetro de sintonia. Já Q modela a incerteza sobre o quanto o modelo linearizado deixa de representar

a dinâmica real (erro de linearização, atrito não modelado, discretização) e na prática é um parâmetro de ajuste: Q pequeno demais faz o filtro confiar demais no modelo linear e divergir fora da vizinhança da vertical (o regime do *swing-up*); Q grande demais aproxima o KF de uma fusão ponderada simples, perdendo a vantagem de usar o modelo. Ajustamos Q diretamente no tempo discreto, e não pela discretização rigorosa de uma densidade espectral de ruído de processo contínuo — simplificação comum em projetos aplicados [4], mas que vale registrar: Q aqui é "efetivo", não "físico".

A consistência estatística desse ajuste de Q é o que o teste NEES (*Normalised Estimation Error Squared*), em `compute_metrics.m`, mede: sob as hipóteses acima, $e_k^T P_k^{-1} e_k$ segue uma distribuição χ^2 com 4 graus de liberdade (dimensão do estado); NEES sistematicamente acima do intervalo esperado indica P otimista (subestima o erro real, tipicamente Q ou R pequenos demais), e abaixo indica P pessimista (superestima o erro) [4]. O mesmo raciocínio, aplicado à inovação $\nu_k = z_k - C_d \hat{X}_k^-$ em vez do erro de estado, dá o teste NIS (χ^2 com 2 graus de liberdade), também em `compute_metrics.m`.

Sensibilidade a Q/R mal ajustados (cenário S5). O cenário S5 testa exatamente esse ponto: o sensor continua gerando ruído nominal, mas os estimadores recebem covariâncias erradas, $Q_{\text{visto}} = 10Q$ e $R_{\text{visto}} = R/10$ (Seção 8 traz a tabela completa com os cinco estimadores). O efeito é o previsto pela teoria: o KF confia mais na medição e menos na predição do que deveria, subestimando o erro real que sua própria covariância indica. O NEES médio do KF sobe de 1,66 em S1 (dentro do intervalo χ_4^2 a 95%, [0,48; 11,14]) para 19,19 em S5 — acima do limite superior, confirmando P otimista. O RMSE de θ quase não piora ($0,24^\circ \rightarrow 0,29^\circ$): o ganho ainda funciona razoavelmente bem na prática, mas o filtro passa a relatar uma incerteza menor que a real — o tipo de falha que só o teste de consistência expõe, e que um RMSE sozinho esconderia.

7.4 Síntese comparativa

A Tabela 3 resume as diferenças estruturais entre os três estimadores desta seção.

Estimador		Modelo dinâmico	Ganho	P tem significado estatístico?
Baseline	(passa-baixas)	Nenhum	Fixo (α_{lp})	Não
Complementar		Implícito (veloc. constante)	Fixo (α_{comp})	Não
KF linear		A_d, B_d (linearizado)	Ótimo, variável (K_k)	Sim (sob hipóteses lineares/gaussianas)

Tabela 3: Comparação estrutural dos três estimadores clássicos implementados.

Metodologia. Antes de avaliar os cinco estimadores na malha fechada completa e nos seis cenários S1–S6 (Seção 8), isolamos os três estimadores clássicos num teste controlado (`tests/test_classical_fil`

que (i) confere numericamente a linearização de `linearise_upright.m` contra o Jacobiano analítico independente `jacobian_f.m` — as duas batem a menos de 10^{-8} ; (ii) simula uma trajetória próxima ao cenário S1 (haste a 5° da vertical) sob realimentação do estado verdadeiro ($u = -K_{demo}X$), com o ganho K já publicado na Seção 4.4 — escolha deliberada para isolar o desempenho de cada estimador dos efeitos do controlador, retomada na discussão abaixo; e (iii) roda os três estimadores em paralelo sobre essa trajetória, com ruído nominal e com o multiplicador $10\times$ do cenário S3.

Resultados. A Tabela 4 e as Figuras 2–3 resumem o que observamos.

Estimador	RMSE θ , S1 ($^\circ$)	RMSE θ , S3 ($^\circ$)	RMSE x , S1 (m)	RMSE x , S3 (m)
Baseline (passa-baixas)	0,250	1,018	0,0031	0,0175
Complementar	1,036	2,500	0,0093	0,0388
KF linear	0,241	1,157	0,0043	0,0188

Tabela 4: RMSE de θ e de x para os três estimadores clássicos, no cenário de demonstração descrito acima, com ruído nominal (S1) e com ruído $10\times$ (S3). Valores gerados por `tests/test_classical_filters.m`.

Dois pontos merecem destaque — um deles contraria a expectativa ingênua de que "mais modelo = sempre melhor":

- **Baseline e KF praticamente empatados, ambos à frente do complementar.** No regime quase-linear e bem amostrado (100 Hz) deste cenário, o passa-baixas bem ajustado ($\alpha_{lp} = 0,8$) e o KF linear entregam RMSE de θ quase idênticos ($0,25^\circ$ *vs.* $0,24^\circ$ com ruído nominal). Isso não contradiz a otimalidade do KF (Seção 7.3.2): o KF é ótimo dado o par (Q, R) configurado, e nesse cenário a trajetória verdadeira vem de uma EDO determinística, sem ruído de processo de fato injetado — ou seja, o Q de `params.m` (Tabela 2), calibrado para representar erro de linearização e dinâmica não modelada, fica relativamente "generoso" frente ao ruído de processo real (próximo de zero) deste cenário. Isso dá ao ganho do KF mais folga do que o necessário, deixando passar um pouco mais de ruído de medição do que um passa-baixas fortemente suavizante deixaria — o mesmo fenômeno de sensibilidade a Q/R mistunado que o cenário S5 expõe (Seção 7.3.2). A vantagem estrutural do KF (explorar A_d, B_d) deve ficar mais evidente com ruído de processo real ou com Q recalibrado — ambos fora do escopo desta seção.
- **Filtro complementar é o pior dos três, por larga margem.** A Figura 2 mostra o motivo: com o ganho padrão $\alpha_{comp} = 0,02$ (Seção 7.2), o filtro confia 98% na predição de velocidade constante a cada passo e corrige devagar pela medição — adequado para deriva lenta, mas lento demais para acompanhar a oscilação inicial rápida de 5° deste cenário: o filtro passa de 6° e só converge por volta de $t \approx 2$ s, enquanto baseline e KF acompanham a verdade quase de imediato. Sob ruído $10\times$ (S3), seu RMSE mais que dobra ($1,04^\circ \rightarrow 2,50^\circ$), a maior degradação relativa das três — esperado, já que α_{comp} é fixo e não se adapta ao novo nível de ruído, ao contrário do ganho K_k do KF, recalculado a cada passo.

Não testamos os três estimadores desta seção no *swing-up* (cenário S2, ângulos grandes): a comparação acima usa de propósito a realimentação do estado verdadeiro ($u = -K_{demo}X$), e não da estimativa, para isolar o desempenho dos filtros dos efeitos do controlador antes de avaliar a malha fechada por completo. É justamente no swing-up que a linearização por trás do KF deixa de valer; a comparação dos cinco estimadores nesse regime, com a malha fechada real ($u = -K\hat{X}$ via `swingup.m`), está na Seção 8.




Figura 2: Ângulo θ estimado pelos três estimadores clássicos no cenário de demonstração (análogo a S1, 5° de perturbação inicial, ruído nominal) *vs.* estado verdadeiro simulado. O filtro complementar (ganho fixo $\alpha_{comp} = 0,02$) *overshoota* e leva ~ 2 s para convergir; baseline e KF acompanham a verdade quase imediatamente.




Figura 3: RMSE de θ dos três estimadores clássicos no cenário de demonstração, com ruído nominal e com ruído $10\times$ (análogo a S1 vs. S3). O complementar tem a maior degradação relativa; baseline e KF permanecem próximos em ambos os níveis.

Da comparação isolada à malha fechada completa. A planta não-linear (`plant_cartpole.m`), o sensor com *dropout/outliers* (`sensor_model.m`), o LQR (`controller_lqr.m`) e o *swing-up* (`swingup.m`) são integrados por `run_scenario.m/main.m` (`src/main.m` roda os cinco estimadores nos seis cenários S1–S6 e salva `results/*.mat`). A Seção 8 traz os resultados dessa malha real — com uma diferença importante frente à comparação isolada acima: ali o ganho K_{demo} realimentava o estado verdadeiro; na malha real $u = -K\hat{X}$ realimenta a estimativa, então um estimador ruim degrada o próprio controle (e não só o RMSE do estimador isolado) — o princípio da separação em ação, não só em teoria.

8 Estimadores de Estado Não-Lineares: EKF e UKF

O KF linear (Seção 7.3) só é ótimo perto do ponto de linearização $\theta = 0$; fora dessa vizinhança — o regime do *swing-up* (cenário S2) — nada garante nem sua estabilidade. Esta seção trata os dois estimadores que lidam com a não-linearidade diretamente: o Filtro de Kalman Estendido (EKF), que relineariza a cada passo em torno da estimativa corrente, e o Filtro de Kalman Unscented (UKF), que propaga a incerteza por um conjunto determinístico de pontos (*sigma points*) através do modelo não-linear exato, sem linearização analítica. Ambos seguem a mesma interface *drop-in* das seções anteriores, $[\hat{X}_k, P_k] = \text{estimator_update}(\hat{X}_{k-1}, P_{k-1}, z_k, u_k, p)$, e retornam opcionalmente $\text{dbg} = (\nu_k, S_k)$ para o teste de consistência NIS em `compute_metrics.m`.

8.1 Filtro de Kalman Estendido (EKF)

8.1.1 Jacobiano analítico

O EKF precisa, a cada passo, de uma aproximação linear local da dinâmica em torno da estimativa corrente $\hat{X}_{k-1}$. Em vez de linearizar uma única vez (Seção 3), `jacobian_f.m` calcula $F = \partial f / \partial X$ analiticamente, em qualquer estado, reaproveitando a mesma solução do sistema 2×2 de `plant_cartpole.m` ($\Delta = aJ - h^2$, Seção 3) e aplicando a regra do quociente às expressões de $\ddot{x}$ e $\ddot{\theta}$. Como a dinâmica não depende de x , a coluna correspondente de F é sempre nula; o restante é avaliado em $(\hat{x}_2, \hat{x}_3, \hat{x}_4, u)$ a cada chamada. Verificamos a corretude contra diferenças finitas centrais e contra a linearização de `linearise_upright.m` em $\theta = 0$ (Seção 8.3).

8.1.2 Predição: integração não-linear + covariância linearizada localmente

Diferentemente do KF, cuja predição é uma multiplicação matricial fixa ($A_d \hat{X}_{k-1} + B_d u_{k-1}$), o EKF integra a dinâmica não-linear completa (RK4, mesmo integrador da planta verdadeira) para propagar a média:

$$\hat{X}_k^- = \text{RK4}(f, \hat{X}_{k-1}, u_{k-1}, \Delta t),$$

e usa o Jacobiano *congelado* em $\hat{X}_{k-1}$, discretizado pela mesma exponencial de matriz da Seção 7.3.1 (sem termo de entrada, pois só a covariância é propagada dessa forma):

$$F = \text{jacobian_f}(\hat{X}_{k-1}, u_{k-1}, p), \quad F_d = e^{F \Delta t}, \quad P_k^- = F_d P_{k-1} F_d^\top + Q.$$

A média segue a física exata; só a incerteza usa uma aproximação linear local, recalculada a cada passo no ponto atual (ao contrário do (A_d, B_d) fixo do KF) — é essa relinearização contínua que permite ao EKF acompanhar o *swing-up* sem perder a estimativa (Seção 8.4).

8.1.3 Atualização

O modelo de medição continua linear ($z = CX$, mesma matriz C da Seção 7.3), de modo que a atualização tem a mesma forma do KF, na forma de Joseph (Seção 7.3.2):

$$S_k = C P_k^- C^\top + R, \quad K_k = P_k^- C^\top S_k^{-1}, \quad \hat{X}_k = \hat{X}_k^- + K_k \nu_k, \quad \nu_k = z_k - C \hat{X}_k^-, \\ P_k = (I - K_k C) P_k^- (I - K_k C)^\top + K_k R K_k^\top.$$

Em *dropout* (S4, $z_k = [\text{NaN}, \text{NaN}]^\top$), o EKF pula a atualização e retorna $(\hat{X}_k^-, P_k^-)$, a mesma convenção dos demais estimadores (Seção 6).

8.2 Filtro de Kalman Unscented (UKF)

8.2.1 Motivação: aproximar a distribuição, não a função

O EKF lineariza a função de transição a cada passo — uma aproximação de primeira ordem que descarta termos de ordem ≥ 2 e introduz viés quando a curvatura de f é grande. O UKF [5]

aproxima, em vez disso, a distribuição de probabilidade: escolhemos deterministicamente um pequeno conjunto de pontos (*sigma points*) que reproduzem exatamente a média e a covariância de $\hat{X}_{k-1}$, propagamos cada um pela dinâmica não-linear exata (RK4, sem aproximação) e reconstruímos a média e a covariância a posteriori a partir dos pontos transformados. O resultado é exato até 2ª ordem de Taylor da média (3ª se a entrada for gaussiana), uma ordem a mais que o EKF, sem exigir Jacobiano.

8.2.2 Sigma points e pesos (transformada *unscented* escalonada)

A implementação (`est_ukf.m`) segue a forma escalonada de Van der Merwe [5]. Para $n = 4$, três parâmetros controlam a dispersão: α (tipicamente 10^{-3}), β ($= 2$, ótimo para gaussianas) e κ (geralmente 0), com

$$\lambda = \alpha^2(n + \kappa) - n.$$

Os $2n + 1 = 9$ *sigma points* são a média mais/menos as colunas da raiz de Cholesky da covariância escalada,

$$\mathcal{X}_0 = \hat{X}_{k-1}, \quad \mathcal{X}_i = \hat{X}_{k-1} \pm \left(\sqrt{(n + \lambda)P_{k-1}} \right)_i, \quad i = 1, \dots, n,$$

com pesos

$$W_0^{(m)} = \frac{\lambda}{n + \lambda}, \quad W_0^{(c)} = \frac{\lambda}{n + \lambda} + (1 - \alpha^2 + \beta), \quad W_i^{(m)} = W_i^{(c)} = \frac{1}{2(n + \lambda)} \quad (i \geq 1).$$

Se a fatoração de Cholesky de P_{k-1} falha (S6), o código regulariza somando $10^{-6}I$ antes de tentar de novo.

8.2.3 Predição

Cada um dos $2n + 1$ *sigma points* é propagado pela dinâmica não-linear completa (RK4, sem aproximação), e a média e a covariância previstas são reconstruídas por combinação ponderada:

$$\mathcal{X}_i^- = \text{RK4}(f, \mathcal{X}_i, u_{k-1}, \Delta t), \quad \hat{X}_k^- = \sum_{i=0}^{2n} W_i^{(m)} \mathcal{X}_i^-,$$

$$P_k^- = Q + \sum_{i=0}^{2n} W_i^{(c)} (\mathcal{X}_i^- - \hat{X}_k^-) (\mathcal{X}_i^- - \hat{X}_k^-)^\top.$$

8.2.4 Atualização

Em geral o UKF propagaria os *sigma points* também pelo modelo de medição $h(\cdot)$. Aqui, porém, $h(X) = CX$ é linear (mesma matriz C do KF/EKF), e propagar os pontos por h daria exatamente $CP_k^-C^\top + R$ — o mesmo resultado da forma fechada do KF. A implementação explora essa igualdade direto, sem reamostrar:

$$S_k = CP_k^- C^\top + R, \quad K_k = P_k^- C^\top S_k^{-1}, \quad \hat{X}_k = \hat{X}_k^- + K_k \nu_k, \quad \nu_k = z_k - C \hat{X}_k^-,$$

$$P_k = (I - K_k C) P_k^-.$$

Diferentemente do KF e do EKF, essa atualização não usa a forma de Joseph — como a álgebra é exata (h já é linear), o ganho de estabilidade numérica é menor aqui. O caso de *dropout* segue a mesma convenção dos demais estimadores: sem atualização, retornamos $(\hat{X}_k^-, P_k^-)$.

8.3 Verificação numérica

`tests/test_nonlinear_filters.m` valida três propriedades:

1. **Jacobiano analítico vs. diferença finita central.** Para seis valores de θ (incluindo 0, $\pm\pi/2$ e π), o erro máximo entre `jacobian_f.m` e diferença finita central de `plant_cartpole.m` foi $2,51 \times 10^{-9}$, abaixo da tolerância de 10^{-6} em todo o domínio de θ .
2. **Smoke tests.** Em duas trajetórias sintéticas, $\hat{X}$ e P ficam finitos e P simétrica positiva-semidefinida (via `chol`) em todos os passos, mesmo atravessando *dropout*, sem produzir NaN/Inf.
3. **Interface.** Chamadas com e sem o argumento de depuração `dbg` funcionam; `dbg` vem vazio quando a medição é perdida.

Os sete testes passam (ALL TESTS PASSED).

8.4 Resultados: divergência do KF fora do regime linear (*swing-up*, S2)

Com a malha fechada completa (Seção 7.4), rodamos os cinco estimadores no cenário mais exigente: o *swing-up* (S2), em que a haste passa por $\theta \in (-\pi, \pi]$ antes de ser capturada pelo LQR — exatamente o regime para o qual a linearização do KF em $\theta = 0$ não foi projetada.




Figura 4: Ângulo θ verdadeiro *vs.* estimado pelos cinco estimadores durante o *swing-up* completo (S2, malha fechada real com `swingup.m`). Baseline e KF acompanham a verdade razoavelmente bem enquanto o pêndulo ainda executa poucos balanços, mas o KF passa a oscilar sem relação com a verdade assim que o ângulo cruza regiões distantes de $\theta = 0$; EKF e UKF (roxo/verde) colam na verdade (preto) do início ao fim, inclusive durante os balanços de 180° .




Figura 5: NEES ao longo do *swing-up* (S2) para KF, EKF e UKF (escala log). A faixa tracejada é o intervalo χ^2_4 a 95%, $[0,48; 11,14]$. O KF passa a maior parte do tempo **quatro a cinco ordens de grandeza** acima do limite superior — o próprio filtro "acredita" ter convergido (sua covariância P encolhe) ao mesmo tempo em que o erro real explode, o padrão clássico de **divergência otimista** de um filtro linear fora de sua região de validade. EKF e UKF permanecem dentro (ou muito perto) da faixa esperada o tempo todo.

A Tabela 5 quantifica o que as Figuras 4 e 5 mostram.

Estimador	RMSE θ (°)	RMSE $\dot{\theta}$ (rad/s)	NEES médio	NEES $\leq \chi^2_{4,97.5\%}$?
Baseline	9,75	2,73	7,81	aprox. (limítrofe)
Complementar	51,62	12,89	223,17	não
KF linear	10,51	90,44	251699,13	não (diverge)
EKF	0,24	0,04	1,73	sim
UKF	0,23	0,03	1,58	sim

Tabela 5: Desempenho no *swing-up* (S2), malha fechada real ($u = -K\hat{X}$ via `swingup.m`), Monte Carlo de uma semente (`rng` fixado pelo harness). O RMSE de $\dot{\theta}$ do KF (90,4 rad/s) é o sintoma mais direto da divergência: o ganho calculado a partir de um modelo linearizado errado deixa de fazer sentido físico.

O KF linear não é só pior: ele diverge de forma otimista — sua própria covariância P relata confiança crescente exatamente quando o erro real explode (Figura 5), o que o tornaria perigoso numa malha real. O baseline, sem modelo algum a "proteger", simplesmente segue a medição filtrada — ruim (RMSE 9,75°) mas nunca catastrófico. Confirma-se o argumento da Introdução: o KF linear compensa só no regime quase-linear; fora dele, um modelo errado pode ser pior que nenhum modelo, e é aí que EKF e UKF, com o modelo não-linear correto, se destacam.

8.5 Síntese comparativa final: cinco estimadores, seis cenários

A Tabela 6 reúne o RMSE de θ para os cinco estimadores nos seis cenários (malha fechada real, $u = -K\hat{X}$ via `swingup.m`).

Cenário	Baseline	Complementar	KF	EKF	UKF
S1 — Estabilização	0,58	15,58	0,24	0,25	0,24
S2 — <i>Swing-up</i>	9,75	51,62	10,51	0,24	0,23
S3 — Ruído alto	9,55	16,77	1,06	1,17	1,09
S4 — Baixa taxa/ <i>dropout</i>	0,87	17,58	0,38	0,24	0,26
S5 — Q/R mal ajustados	0,63	15,16	0,29	0,29	0,27
S6 — Inicialização ruim	1,29	15,78	0,24	0,24	0,24

Tabela 6: RMSE de θ (graus) por estimador e cenário, malha fechada real.

Além do já discutido S2:

- **EKF e UKF praticamente empatados** em todos os cenários, já que o modelo de medição é linear (Seção 8.2): a diferença está só em como cada um propaga a predição não-linear, e raramente é decisiva neste projeto. A vantagem do UKF aparece no *swing-up* (S2), com pequena vantagem sobre o EKF (0,23° vs. 0,24°; mais nítida em $\dot{\theta}$, Tabela 5).
- **Regime quase-linear (S1, S4, S5, S6):** KF, EKF e UKF convergem para desempenho parecido, a poucos centésimos de grau um do outro — EKF/UKF não perdem nada por levar um modelo mais caro quando a situação não exige.

- **S5 (Q/R mal ajustados) afeta os três "com modelo" igualmente:** o NEES médio sobe de forma quase idêntica (KF 19,19, EKF 19,66, UKF 18,29, todos acima do limite χ_4^2 de 11,14) — a inconsistência é uma propriedade do ajuste de Q/R , não do tipo de estimador.
- **Anomalia pontual em S6:** sob inicialização ruim ($P_0 = 100I$), o RMSE de $\dot{\theta}$ do UKF sobe para 0,236 rad/s (EKF 0,026, KF 0,045), embora o RMSE de θ fique idêntico (0,24°) — provável transiente nos *sigma points* iniciais, espalhados demais para a dinâmica RK4 de um passo. Não compromete a conclusão geral; fica como candidato a investigação futura.
- **$t_{converge}$ é uma métrica frágil perto do limiar.** Em S3, o KF converge em 3,26 s enquanto EKF/UKF aparecem como NaN, apesar de RMSE de θ comparável ou melhor nos três. A causa é o RMSE de $\dot{\theta}$ colado na tolerância de convergência (0,10 rad/s): `compute_metrics.m` exige os quatro estados dentro da tolerância por 1 s contínuo, e um único passo acima do limite reinicia a janela — sensível à sorte da realização de ruído perto da fronteira. O mesmo explica por que baseline e complementar quase nunca convergem por esse critério.




Figura 6: Custo computacional médio por estimador (`cpu_time`, escala log), medido dentro de `run_scenario.m` e médio sobre os seis cenários. A ordem reflete diretamente a complexidade algorítmica de cada método por passo: baseline e complementar são $O(1)$ (sem álgebra matricial); KF é uma predição/atualização 4×4 fixa; EKF soma o custo de `jacobian_f` + `expm` (4×4) a cada passo; UKF paga por $2n+1 = 9$ integrações RK4 completas da dinâmica não-linear por passo, além da fatoração de Cholesky.

Em termos absolutos (Figura 6), baseline e complementar custam $\sim 1,3\text{--}1,5$ ms por execução completa; o KF, $\sim 6,5$ ms ($5\times$); o EKF, $\sim 42,8$ ms ($33\times$); e o UKF, $\sim 88,6$ ms ($68\times$ o baseline, $2,1\times$ o EKF — preço de propagar 9 pontos por RK4 em vez de 1 Jacobiano). Em nenhum cenário deste projeto o custo é proibitivo, mas a razão EKF/UKF seria o critério decisivo num microcontrolador de malha rápida, onde o EKF dá quase a mesma precisão por metade do custo por passo.

8.6 O que o ruído explica (e o que não explica): revisitando S0

A Seção 5.5 definiu S0 (mesma trajetória de S2, mas com $\sigma_x = \sigma_\theta = 0$) como referência sem ruído. Rodando os cinco estimadores nesse cenário, separamos dois efeitos que o RMSE de S1–S6 mistura: erro causado pelo ruído de medição *vs.* erro estrutural do método, presente mesmo com medição perfeita.




Figura 7: RMSE de θ por estimador em S0 (sem ruído de medição), escala logarítmica. Baseline e complementar mantêm erro de ordem 10^1 mesmo sem ruído algum; KF, EKF e UKF colapsam para $\lesssim 10^{-4}$.

O resultado é nítido: com $\sigma = 0$, KF, EKF e UKF reduzem o RMSE de θ a $5,6 \times 10^{-5}$, $1,1 \times 10^{-8}$ e $1,1 \times 10^{-8}$ respectivamente — a estimativa colapsa para a verdade, como esperado de um filtro bem formulado sem incerteza de medição. Baseline e complementar, porém, não zeram: ficam em $10,28^\circ$ e $51,75^\circ$, praticamente os mesmos valores já vistos em S2 com ruído nominal ($9,75^\circ$ e $51,62^\circ$, Tabela 6). Ou seja, o erro desses dois métodos durante o *swing-up* não vem do ruído do sensor — vem de diferenciar numericamente um sinal que muda rápido demais para a constante de tempo do passa-baixas (Seção 7.1) e para a ponderação fixa do complementar (Seção 7.2), regime não-linear em que nenhum dos dois tem um modelo da dinâmica para se apoiar. Zerar o ruído do sensor não teria ajudado; o problema é estrutural. É o argumento mais

direto deste relatório a favor dos estimadores baseados em modelo (KF/EKF/UKF, cada um dentro de seu regime de validade) sobre as alternativas herdadas do curso.

9 Arquitetura da malha e discussão

A Figura 8 reúne os módulos num diagrama de blocos da malha fechada. O laço opera em tempo discreto (passo Δt): a cada instante o sensor mede as posições ($z = [x; \theta]$ com ruído/perda), o estimador (KF, EKF ou UKF) reconstrói o estado completo $\hat{X}$, o controlador de duas fases gera a força u e a planta não-linear é integrada até o passo seguinte.




Figura 8: Malha de controle com estimação de estados. O controlador nunca acessa o estado verdadeiro: fecha o laço sobre a estimativa $\hat{X}$ (princípio da separação). É neste ponto que se comparam os cinco estimadores.

Dois aspectos merecem destaque. Primeiro, o princípio da separação: o controlador foi projetado supondo acesso ao estado, mas opera sobre $\hat{X}$; a Seção 8.5 quantifica essa degradação — com baseline ou complementar, o LQR (estável por projeto, Seção 4.4) nunca chega ao desempenho da malha ideal, enquanto com KF/EKF/UKF no regime válido a malha real se aproxima da malha com estado verdadeiro. Segundo, o controlador de duas fases (energy shaping + PD longe da vertical, LQR na janela de captura) leva os filtros, num único experimento, por um regime fortemente não-linear e por um quase-linear — mostrando onde cada técnica de estimação compensa, mais nítido na divergência do KF e na robustez de EKF/UKF durante o *swing-up* (Seção 8.4).

Conclusão

Implementamos e comparamos, dentro de uma malha de controle fechada real, quatro níveis de estimadores de estado — diferenciação com passa-baixas, filtro complementar, KF linear, EKF e UKF — aplicados ao pêndulo invertido sobre carro. As conclusões centrais, sustentadas pelos seis cenários (S1–S6) rodados com o harness completo (`src/main.m`):

- **O KF linear é ótimo só perto do ponto onde foi linearizado.** Empata com EKF/UKF no regime quase-linear (S1/S4/S5/S6); no *swing-up* (S2) diverge de forma oti-

mista — a covariância relatada encolhe exatamente quando o erro real explode (NEES $\sim 2,5 \times 10^5$ contra o limite χ_4^2 de 11,14).

- **EKF e UKF resolvem esse problema**, carregando o modelo não-linear correto: RMSE de θ abaixo de $0,25^\circ$ e NEES dentro da faixa esperada nos seis cenários. A diferença entre os dois é pequena aqui; o UKF leva vantagem marginal em regimes fortemente não-lineares, ao custo de $\sim 2\times$ o tempo de CPU do EKF.
- **"Mais modelo" nem sempre é melhor**: o filtro complementar é o pior estimador em quase todo cenário, e o baseline sem modelo supera o KF divergente no *swing-up*.
- **O princípio da separação se verifica na prática**: o mesmo ganho LQR (estável por projeto, Seção 4.4) produz malhas de qualidade muito diferente dependendo do estimador que alimenta $\hat{X}$.
- Os testes de consistência (NEES/NIS) revelam o que o RMSE esconde: em Q/R mal ajustados (S5), o RMSE quase não piora, mas os filtros baseados em modelo relatam incerteza menor que a real — só o teste χ^2 expõe isso.

Como trabalho futuro, ficam abertos: recalibrar Q por um método rigoroso de densidade espectral (em vez do ajuste direto em tempo discreto, Seção 7.3.2); adotar a forma de Joseph também na atualização do UKF (Seção 8.2); e investigar a anomalia pontual de $\dot{\theta}$ do UKF sob inicialização ruim (S6, Seção 8.5).

10 Uso de IA

Usamos nesse projeto o Claude Code, desde a elaboração dos modelos usando matlab até a escrita deste relatório. Apesar do grande auxílio que essa ferramenta trouxe, não deixamos de aprender e utilizar nosso pensamento crítico quanto às decisões de projeto. A concepção do modelo físico foi feita à mão, as implementações dos filtros foram verificadas e o modelo matemático por trás também, com cada aluno cumprindo uma parte do projeto.

Obs: esta seção foi escrita por um humano :)

Referências

- [1] MathWorks. *Derive and Simulate Cart-Pole System* (Symbolic Math Toolbox). Disponível em: <https://www.mathworks.com/help/symbolic/derive-and-simulate-cart-pole-system.html>.
- [2] R. Tedrake. *Underactuated Robotics: Algorithms for Walking, Running, Swimming, Flying, and Manipulation* — Cap. *The Simple Pendulum*. Disponível em: <https://underactuated.mit.edu/pend.html>.

- [3] G. Welch, G. Bishop. *An Introduction to the Kalman Filter*. Technical Report TR 95-041, University of North Carolina at Chapel Hill, 1995 (atualizado em 2006). Disponível em: https://www.cs.unc.edu/~welch/media/pdf/kalman_intro.pdf.
- [4] D. Simon. *Optimal State Estimation: Kalman, H_∞ , and Nonlinear Approaches*. Wiley, 2006.
- [5] E. A. Wan, R. van der Merwe. *The Unscented Kalman Filter for Nonlinear Estimation*. Proc. IEEE Adaptive Systems for Signal Processing, Communications, and Control Symposium (AS-SPCC), pp. 153–158, 2000.
- [6] A. V. Oppenheim, R. W. Schaffer. *Discrete-Time Signal Processing*, 3.^a ed. Prentice Hall, 2009.